



# Insurance Customer

Kecerdasan Artifisial dan Sains Data Dasar Ganjil 2024/2025

- Farah Aura Rosadi - 2206824773
- Muhammad Fawwaz Arshad S - 2206082511
- Rifda Aulia Nurbahri - 2206081660
- Shabhi Aliyya Siyauqi D - 2206083741



Tim Proyek APAP

1

## Business Understanding

2

## Data Understanding

3

## Data Preparation

4

## Data Modelling

5

## Wrap-Up Summary

# Bussiness Understanding

## Deskripsi Dataset

**Modul "Insurance Customer" ini mencakup berbagai informasi tentang pelanggan dari perusahaan asuransi. Modul ini dapat digunakan untuk mengelompokkan pelanggan berdasarkan nilai CLV, tipe polis, dan perilaku klaim**

Dalam modul pembelajaran ini, kita akan mengerjakan beberapa jenis tugas analisis data yaitu, Melakukan analisis data yang mencakup pemahaman dan interpretasi data yang diberikan, Menjalankan eksplorasi data untuk menemukan pola dan wawasan penting, dan Mengembangkan berbagai model prediktif seperti Model Klasifikasi, Regresi, dan Clustering.



1

## Business Understanding

2

## Data Understanding

3

## Data Preparation

4

## Data Modelling

5

## Wrap-Up Summary

# Data Understanding

## Deskripsi Dataset



Dataset berisikan informasi pengguna serta layanan yang disubscribe dari perusahaan asuransi

**Ukuran Dataset**

**24 x 5480**  
kolom                    baris

# Data Understanding

## Deskripsi Kolom

Name	Type	Description
Customer	Object	ID unik untuk setiap pelanggan
State	Object	Negara bagian tempat pelanggan berada.
Customer Lifetime Value	Float	Nilai total yang diberikan oleh pelanggan selama masa hubungannya dengan perusahaan
Response	integer	Respon pelanggan terhadap kampanye pemasaran (Yes/No)
Coverage	Object	Jenis cakupan asuransi yang dimiliki pelanggan (Basic, Extended, Premium)

Name	Type	Description
Education	Object	Tingkat pendidikan pelanggan
Effective To Date	Object	Tanggal mulai efektif polis asuransi
Employment Status	Object	Status pekerjaan pelanggan (Employed, Unemployed, Medical Leave, Disabled, Retired)
Gender	Object	Jenis kelamin pelanggan
Income	Float	Pendapatan tahunan pelanggan
Location Code	Object	Kode lokasi yang menunjukkan urbanisasi daerah tempat tinggal pelanggan (Urban, Suburban, Rural)

Name	Type	Description
Martial Status	Object	Status pernikahan pelanggan (Married, Single, Divorced).
Monthly Premium Auto	Integer	Premi bulanan yang dibayar pelanggan untuk asuransi kendaraan.
Months Since Last Claim	Integer	Jumlah bulan sejak klaim terakhir.
Months Since Policy Inception	Integer	Jumlah bulan sejak polis mulai berlaku.
Number of Open Complaints	Integer	Jumlah keluhan terbuka yang diajukan pelanggan.
Number of Policies	Integer	Jumlah polis yang dimiliki pelanggan.

Name	Type	Description
Policy Type	Object	Jenis polis yang dimiliki pelanggan (Personal Auto, Corporate Auto, Special Auto).
Policy	Object	Detail polis asuransi (Personal L1, Personal L2, Personal L3, dll).
Renew Offer Type	Object	Jenis penawaran pembaruan polis yang diberikan kepada pelanggan (Offer1, Offer2, Offer3, Offer4).
Sales Channel	Object	Kanal penjualan melalui mana pelanggan membeli polis (Agent, Call Center, Web, Branch).
Total Claim Ammount	Float	Total jumlah klaim yang diajukan pelanggan.
Vehicle Class	Object	Kelas kendaraan yang diasuransikan (Two-Door Car, Four-Door Car, SUV, dll).
Vehicle Size	Object	Ukuran kendaraan yang diasuransikan (Small, Medsize, Large).

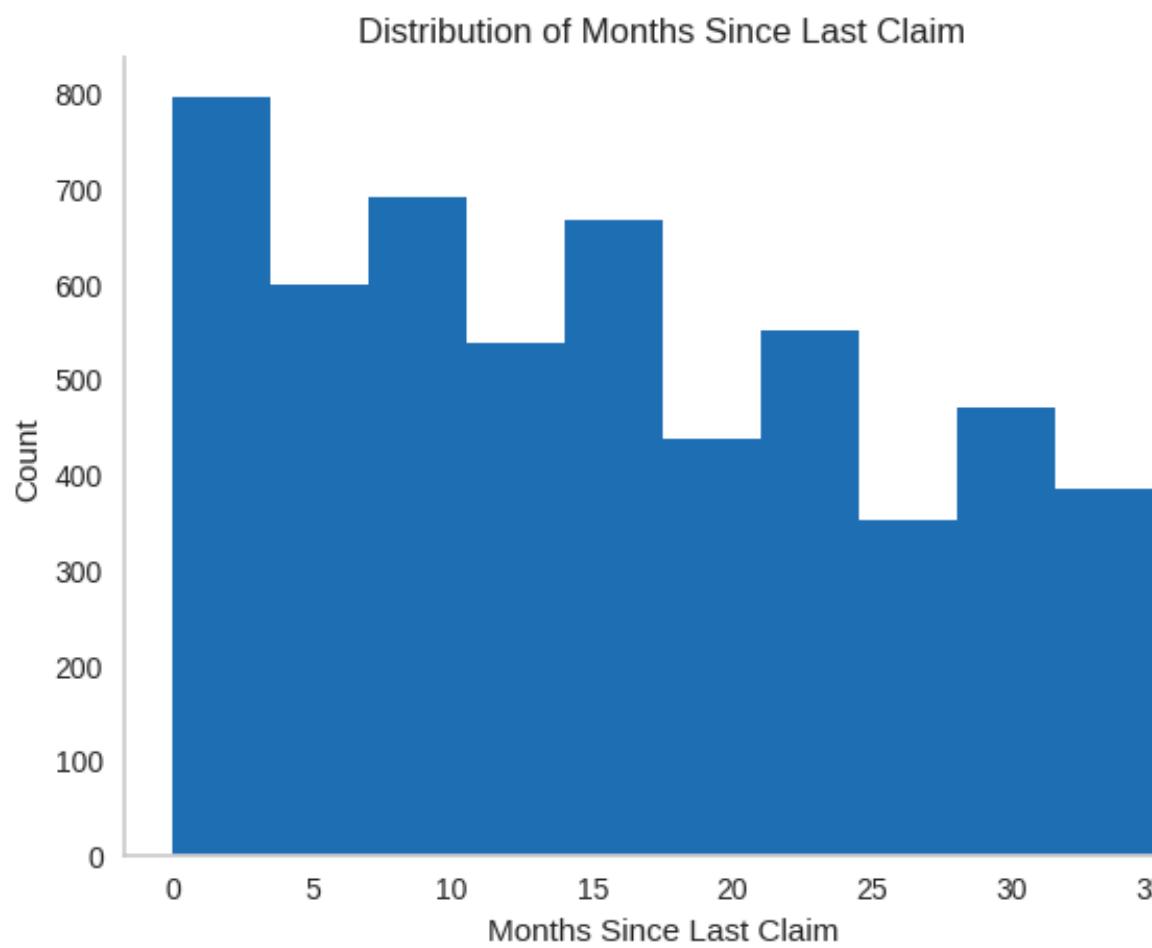
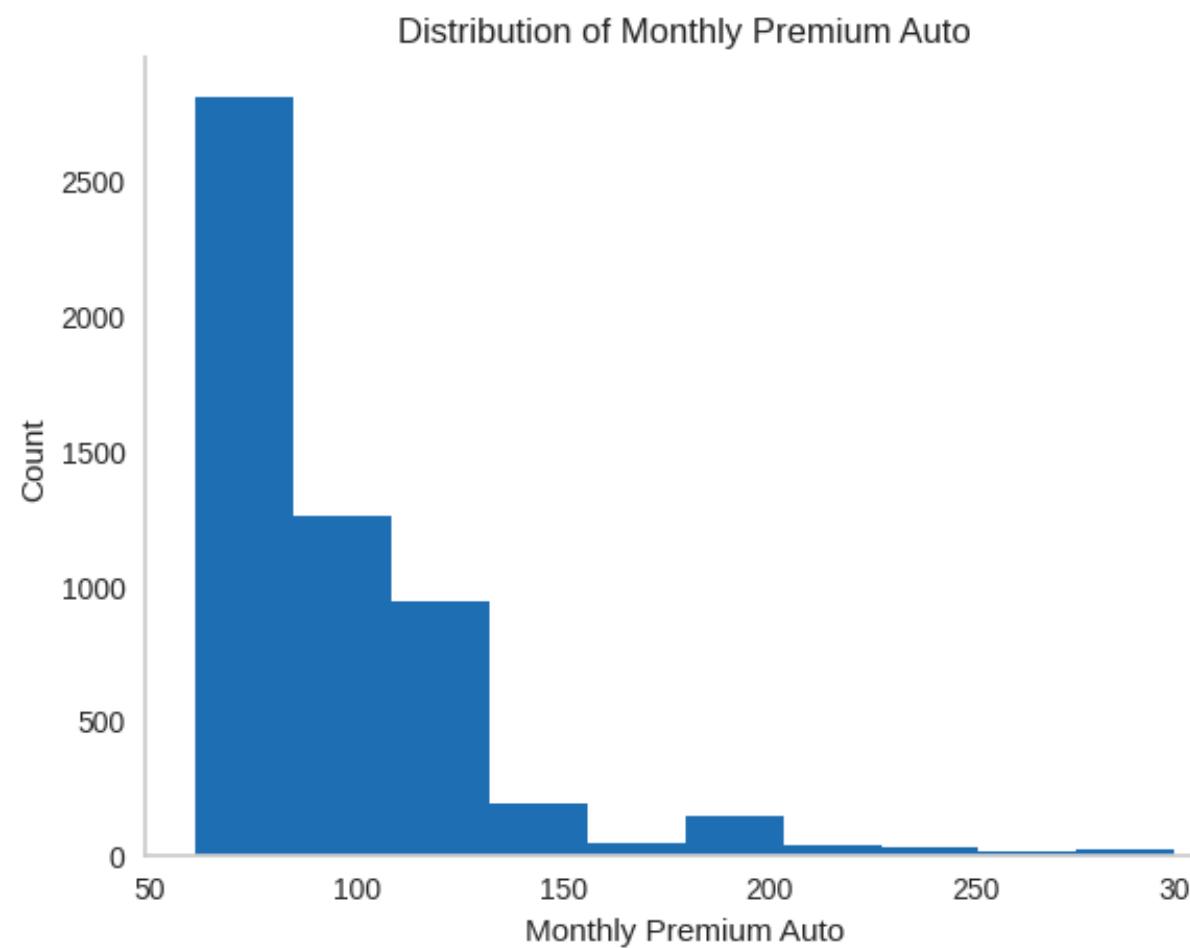
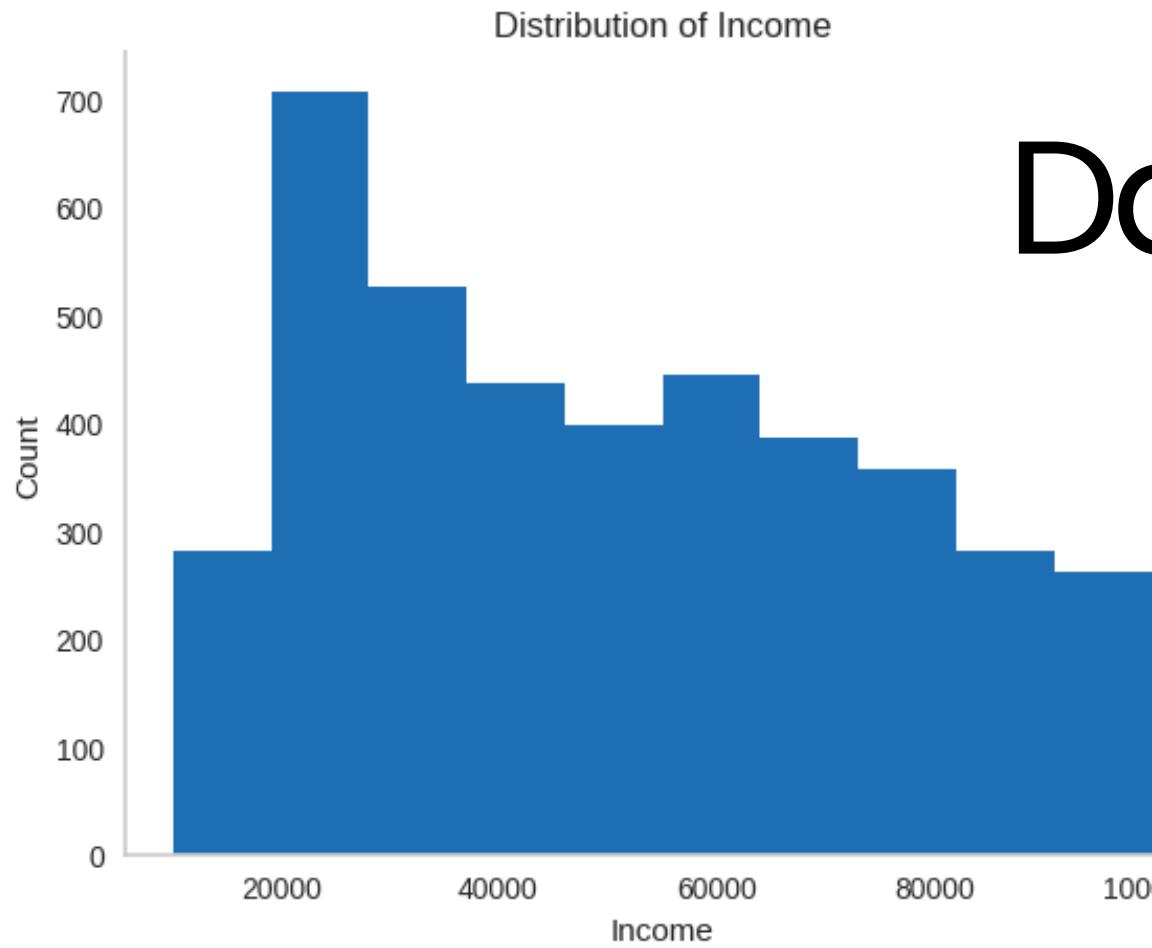
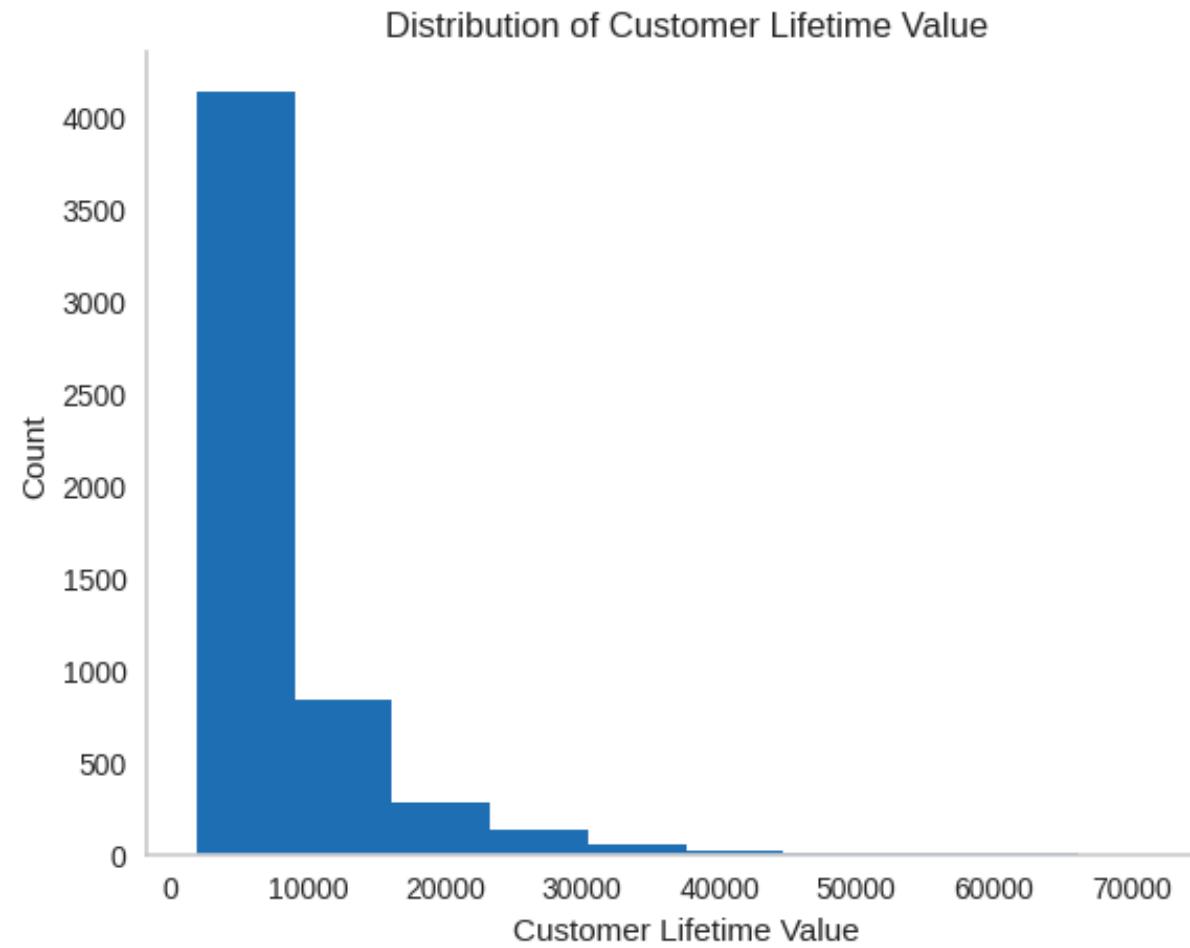
# Data Understanding

## Descriptive Statistics

	Customer Lifetime Value	Response	Income	Monthly Premium Auto	Months Since Last Claim	Months Since Policy Inception	Number of Open Complaints	Number of Policies	Total Claim Amount
count	5480.000000	5480.000000	4076.000000	5480.000000	5480.000000	5480.000000	5480.000000	5480.000000	4563.000000
mean	8001.630793	0.142336	50480.955839	93.479927	15.225365	48.119891	0.371898	2.970255	429.914629
std	6854.186470	0.349426	24296.881547	34.629333	10.029712	28.020285	0.894720	2.400955	283.011212
min	1898.007675	0.000000	10097.000000	61.000000	0.000000	0.000000	0.000000	1.000000	0.423310
25%	4016.927113	0.000000	28432.000000	69.000000	6.000000	24.000000	0.000000	1.000000	267.979586
50%	5801.478197	0.000000	48113.500000	83.000000	14.000000	48.000000	0.000000	2.000000	379.200000
75%	8947.875574	0.000000	70083.500000	109.000000	23.000000	71.000000	0.000000	4.000000	542.400000
max	73225.956520	1.000000	99981.000000	298.000000	35.000000	99.000000	5.000000	9.000000	2452.894264

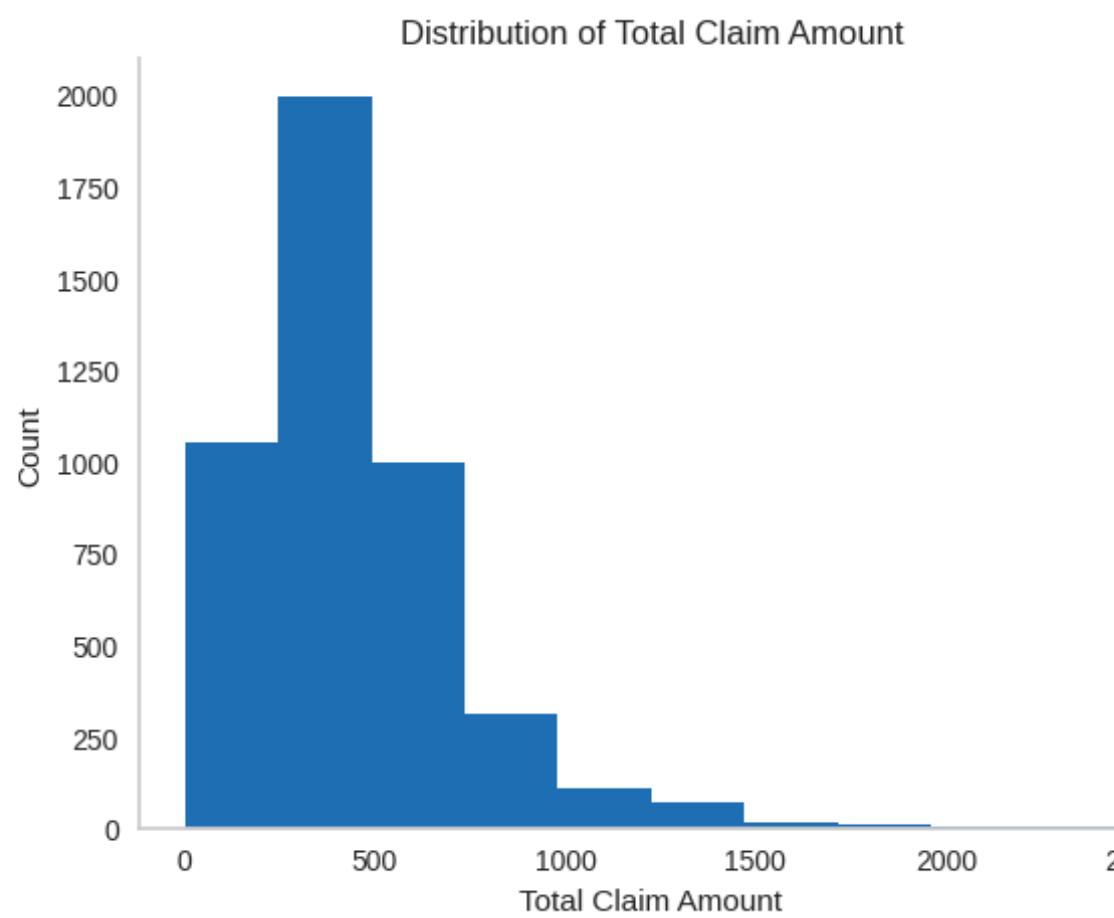
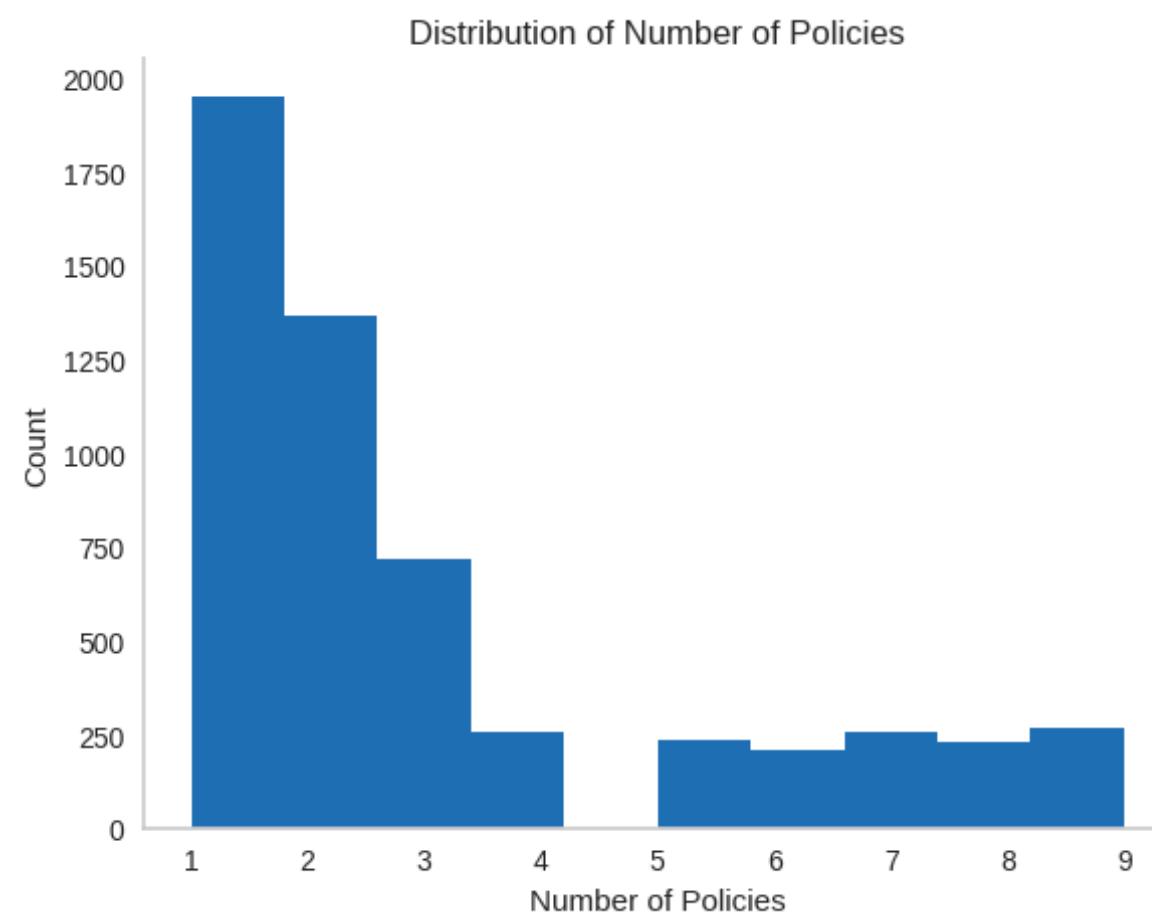
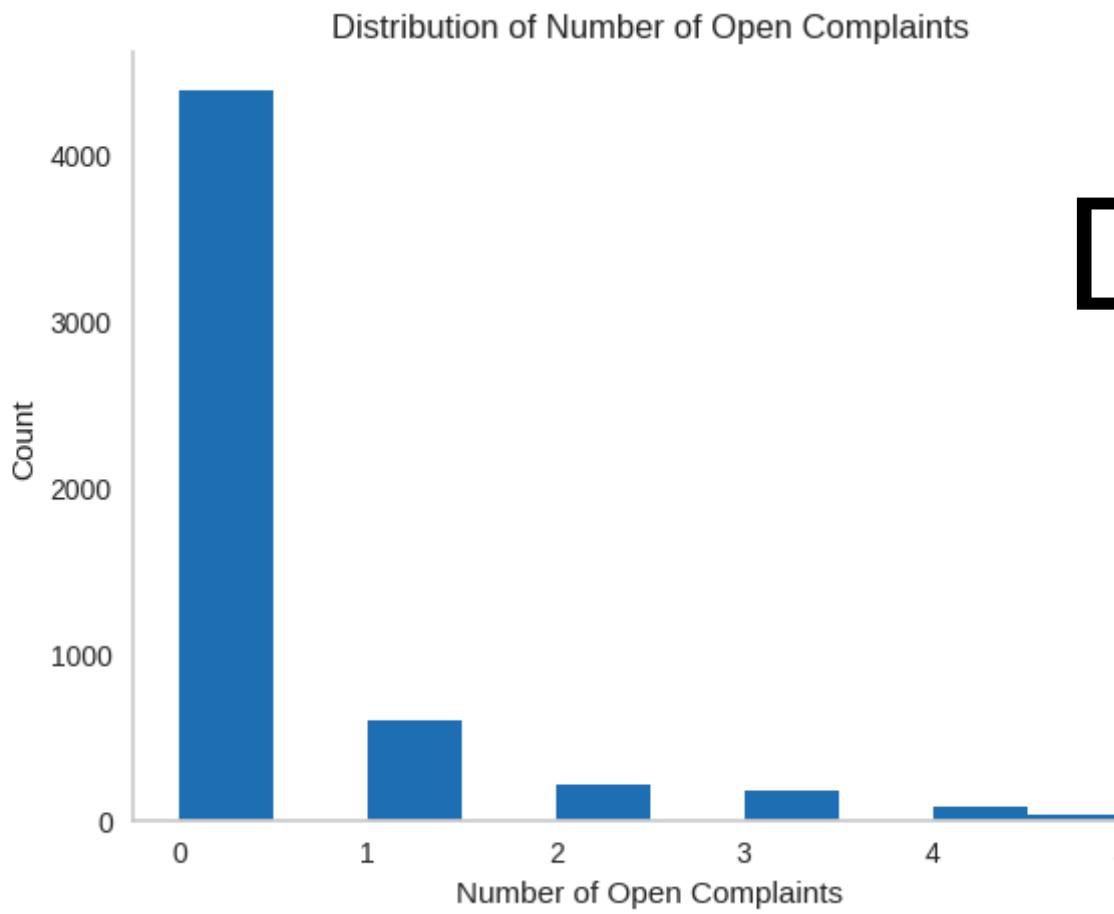
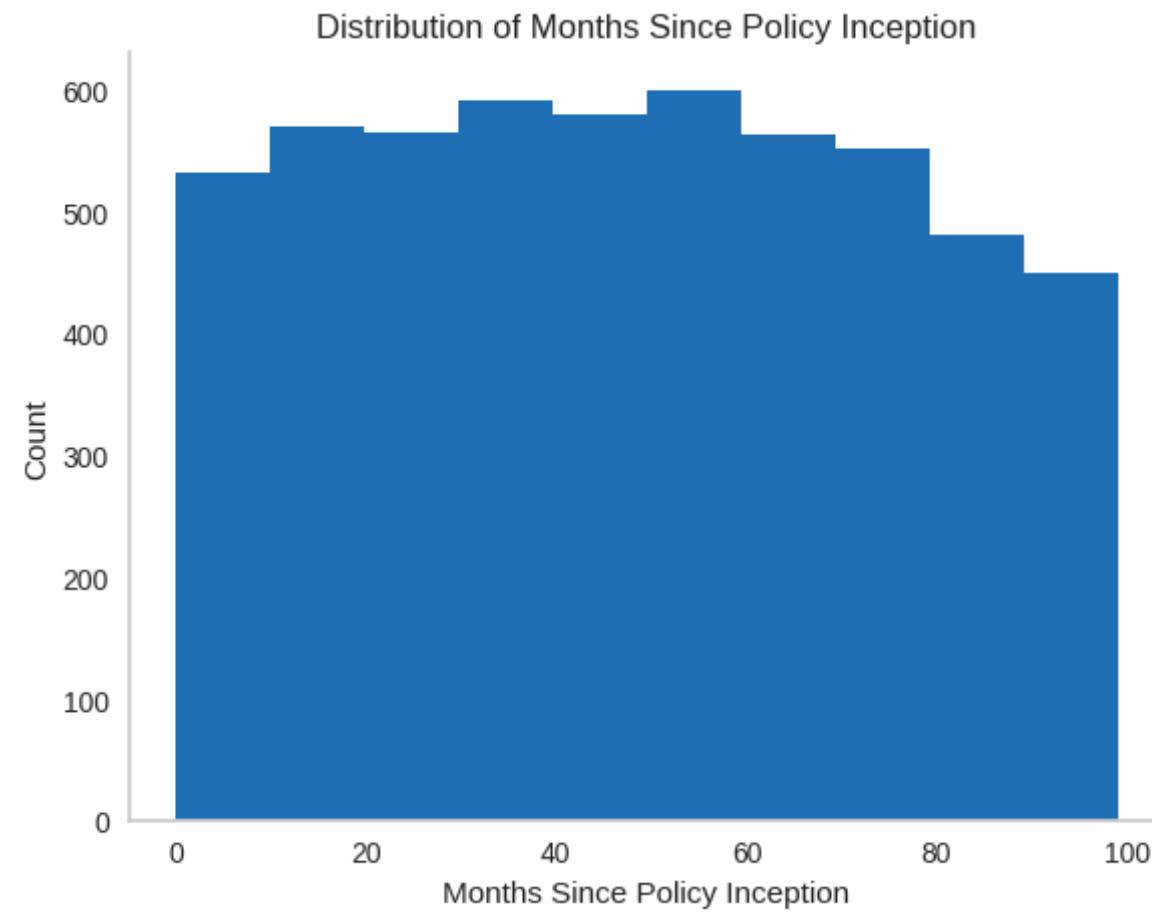
# Data Understanding

## Data Distribution



# Data Understanding

## Data Distribution



# Data Understanding

## EDA

1

Tipe polis mana yang memiliki jumlah klaim rata-rata tertinggi?



- **Corporate Auto**
- **Personal Auto**
- **Special Auto**

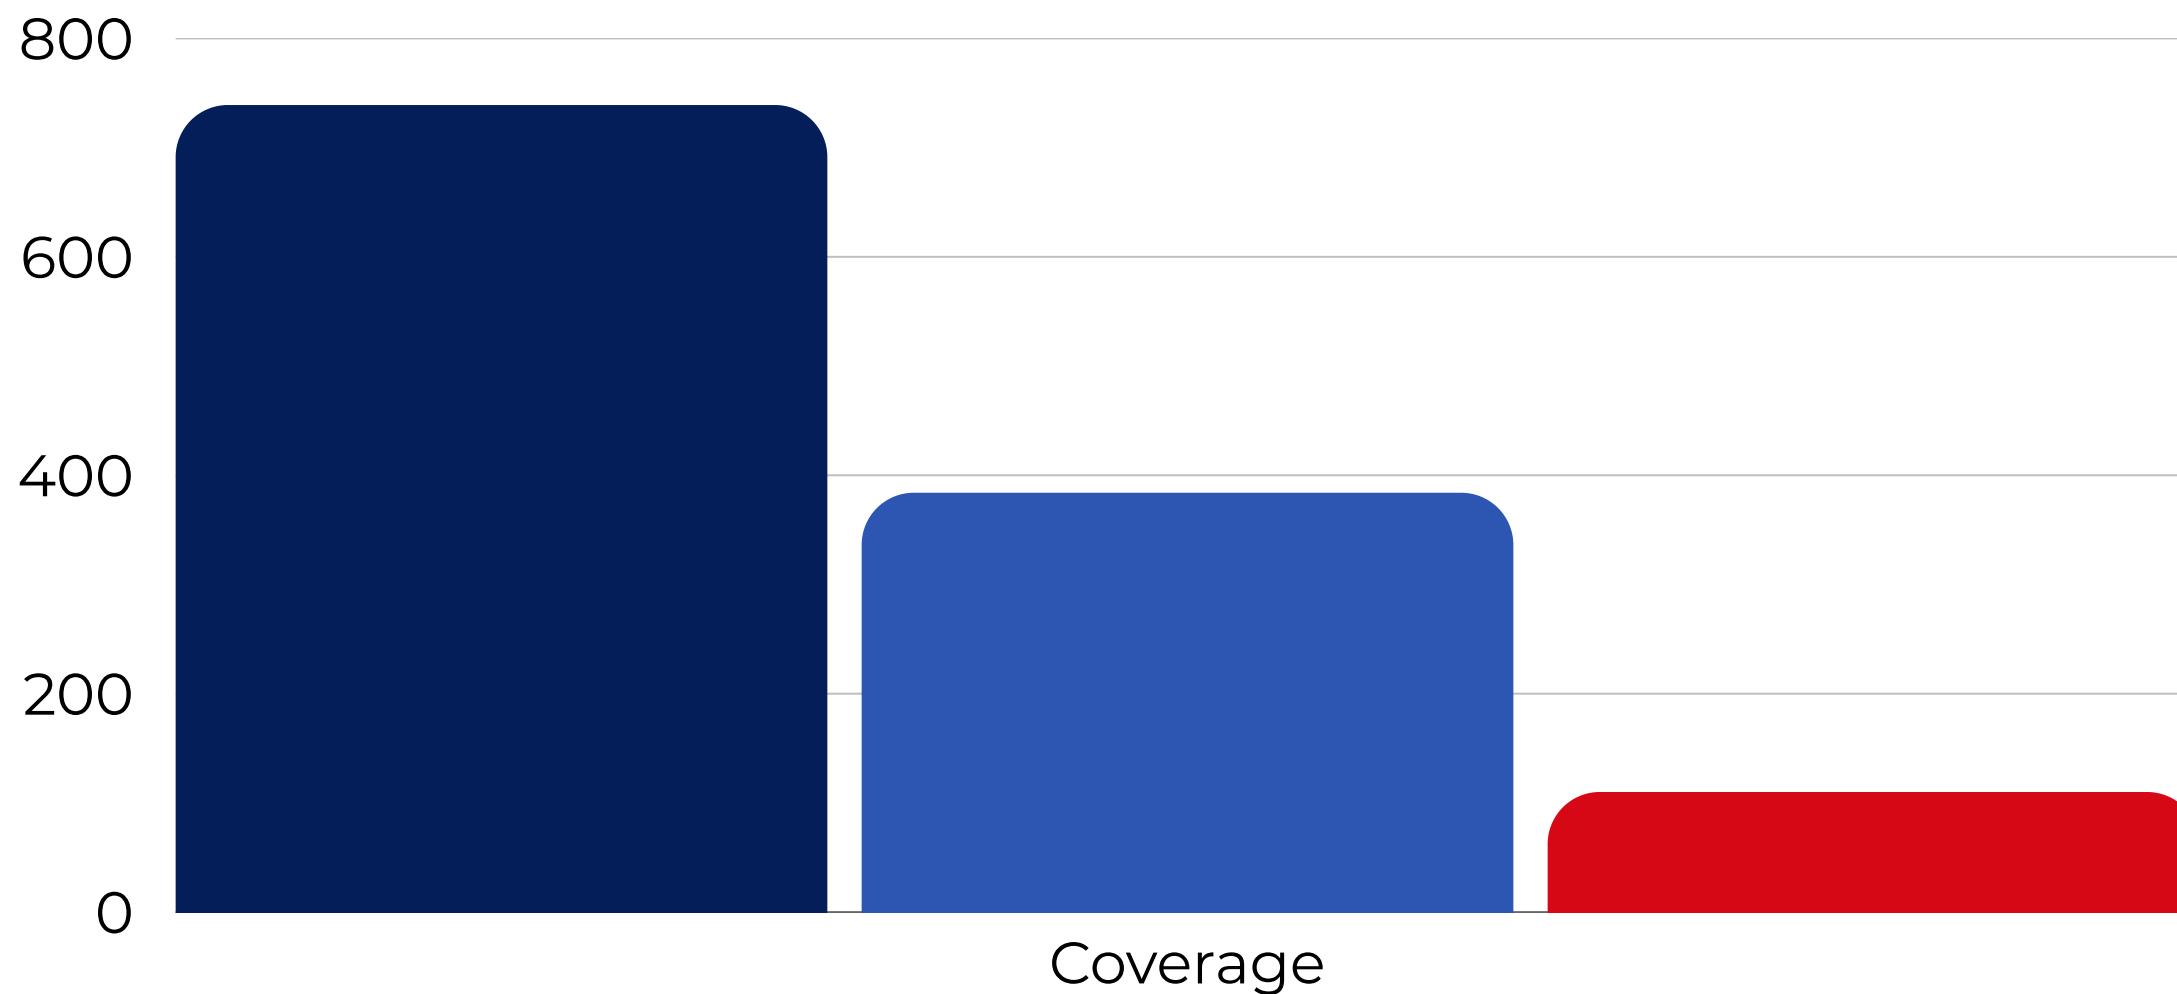
Berdasarkan analisis data klaim asuransi, **Personal Auto mencatat rata-rata klaim tertinggi sebesar 433.9 ribu**, diikuti oleh Special Auto dengan 423.9 ribu, dan Corporate Auto dengan 417.0 ribu. Menariknya, perbedaan rata-rata klaim antar tipe polis relatif kecil, hanya sekitar 4%, yang mengindikasikan konsistensi dalam penilaian risiko di seluruh segmen.

# Data Understanding

## EDA

2

Coverage apa yang paling banyak dimiliki oleh pengguna yang berstatus pekerjaan “Unemployed”



- **Basic**
- **Extended**
- **Premium**

Mayoritas pengguna unemployed memilih **Basic Coverage**, menunjukkan preferensi pada opsi yang lebih terjangkau. Meski unemployed, masih ada 110 pengguna yang memilih Premium Coverage, mengindikasikan adanya segmen pengguna dengan kemampuan finansial yang lebih baik.

# Data Understanding

## EDA



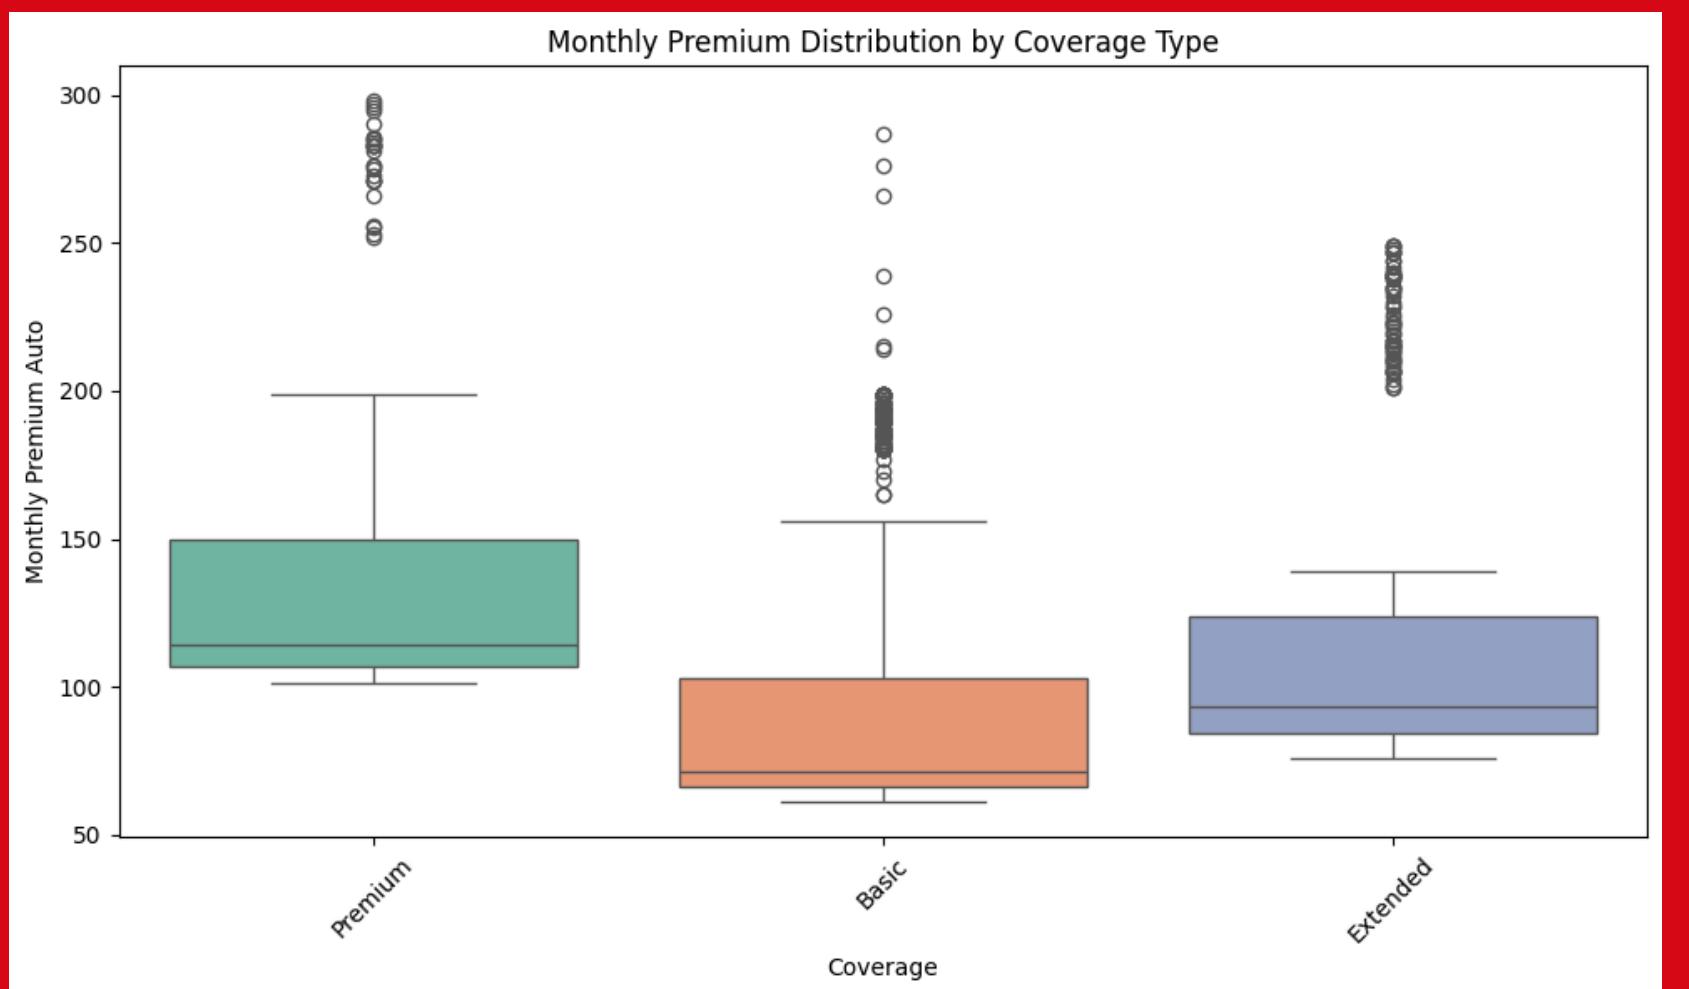
3

Bagaimana hubungan antara Monthly Premium Auto dengan Customer Lifetime Value dan Monthly Premium Auto dengan Coverage?

Terlihat adanya **korelasi positif** yang jelas antara Monthly Premium Auto dengan Customer Lifetime Value di semua jenis coverage (Basic, Extended, dan Premium). Semakin tinggi Monthly Premium Auto, semakin tinggi pula Customer Lifetime Value, namun dengan pola yang menarik. Data menunjukkan pengelompokan bertingkat (*stratified pattern*) dimana nilai Customer Lifetime Value membentuk beberapa lapisan linear yang berbeda. Coverage Extended cenderung memiliki nilai CLV yang lebih tinggi pada rentang premium yang sama, terlihat dari sebaran titik yang dominan di bagian atas. Sebaliknya, Basic coverage umumnya berada di rentang premium yang lebih rendah dengan nilai CLV yang lebih moderat. Pola ini mengindikasikan bahwa strategi penetapan harga premium berpengaruh signifikan terhadap nilai jangka panjang pelanggan, dengan variasi yang berbeda berdasarkan tipe coverage yang dipilih.

# Data Understanding

## EDA



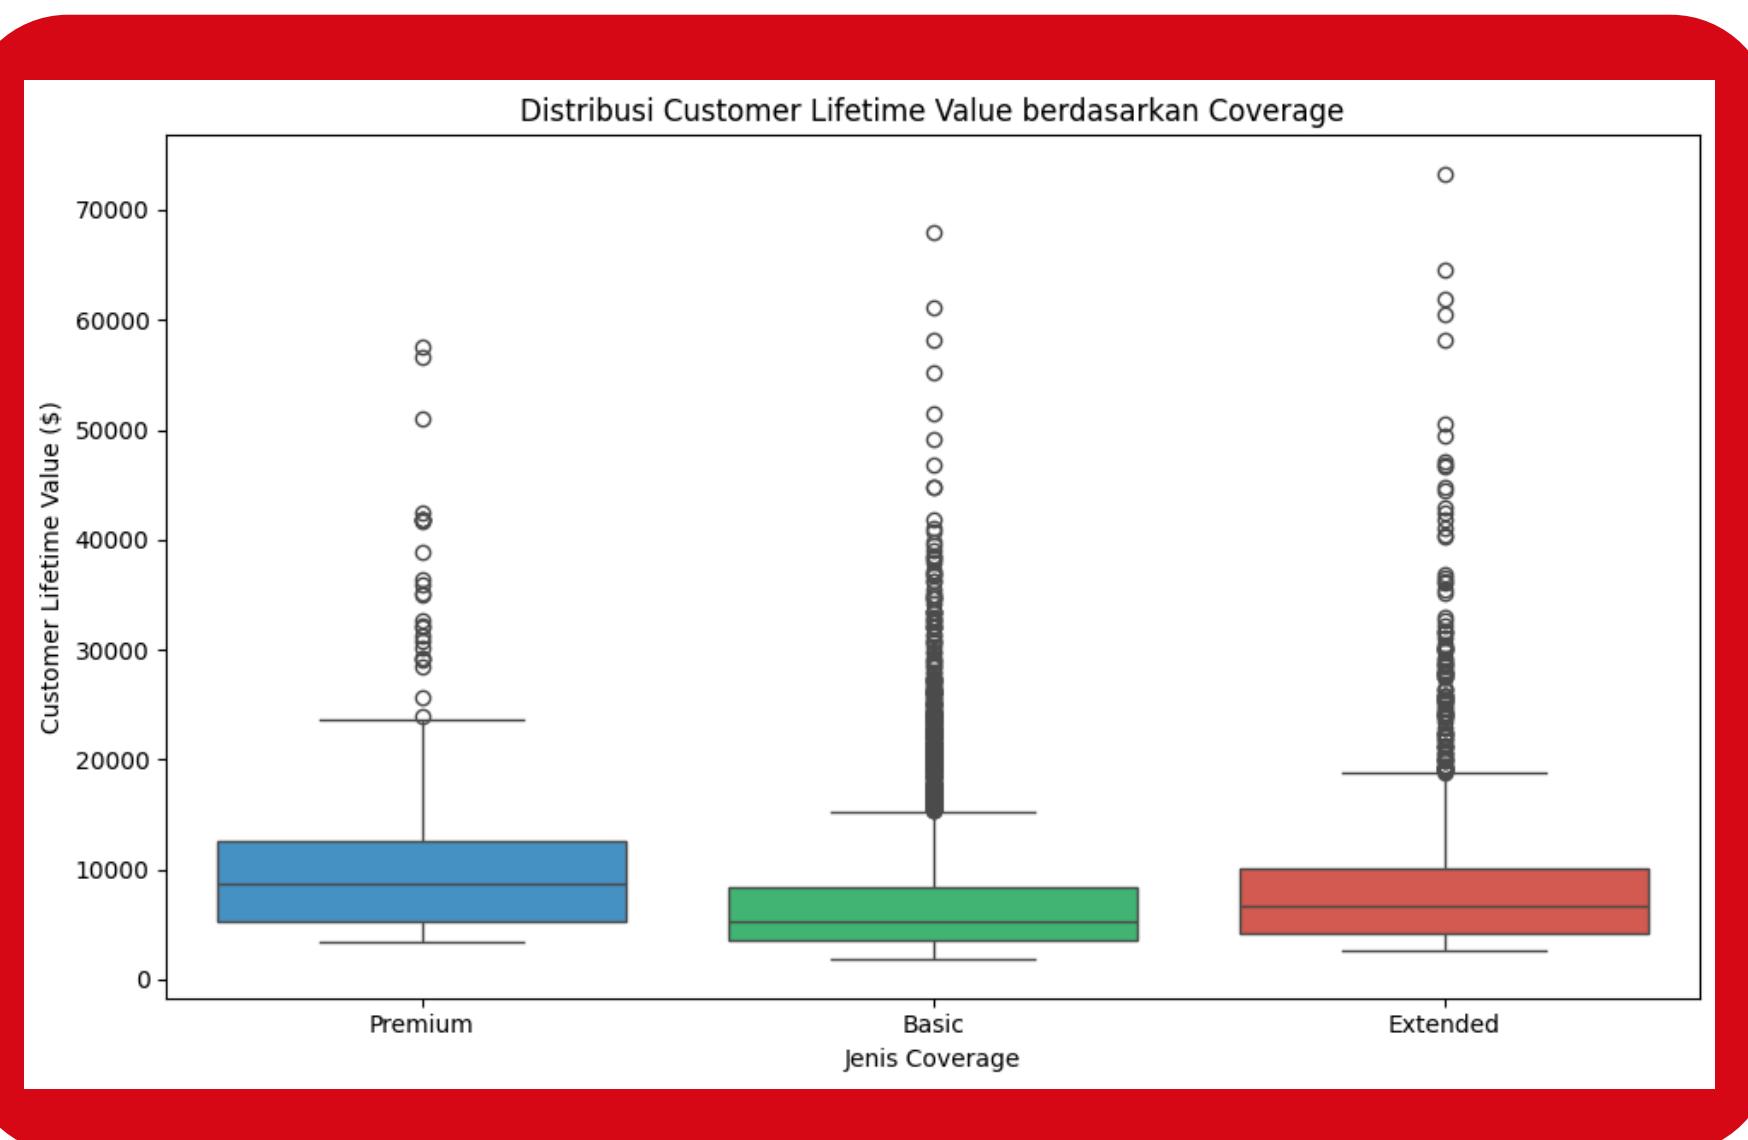
3

Bagaimana hubungan antara Monthly Premium Auto dengan Customer Lifetime Value dan Monthly Premium Auto dengan Coverage?

Berdasarkan visualisasi box plot, terlihat perbedaan distribusi Monthly Premium Auto yang signifikan antar jenis Coverage. Coverage Premium menunjukkan rata-rata premium bulanan tertinggi dengan median sekitar 114, diikuti oleh Extended dengan median 93, dan Basic dengan median terendah yaitu 71. Menariknya, semua jenis coverage memiliki outlier di bagian atas, yang menunjukkan adanya segmen pelanggan yang membayar premium jauh di atas rata-rata kelompoknya, khususnya pada Basic coverage.

# Data Understanding

## EDA



4

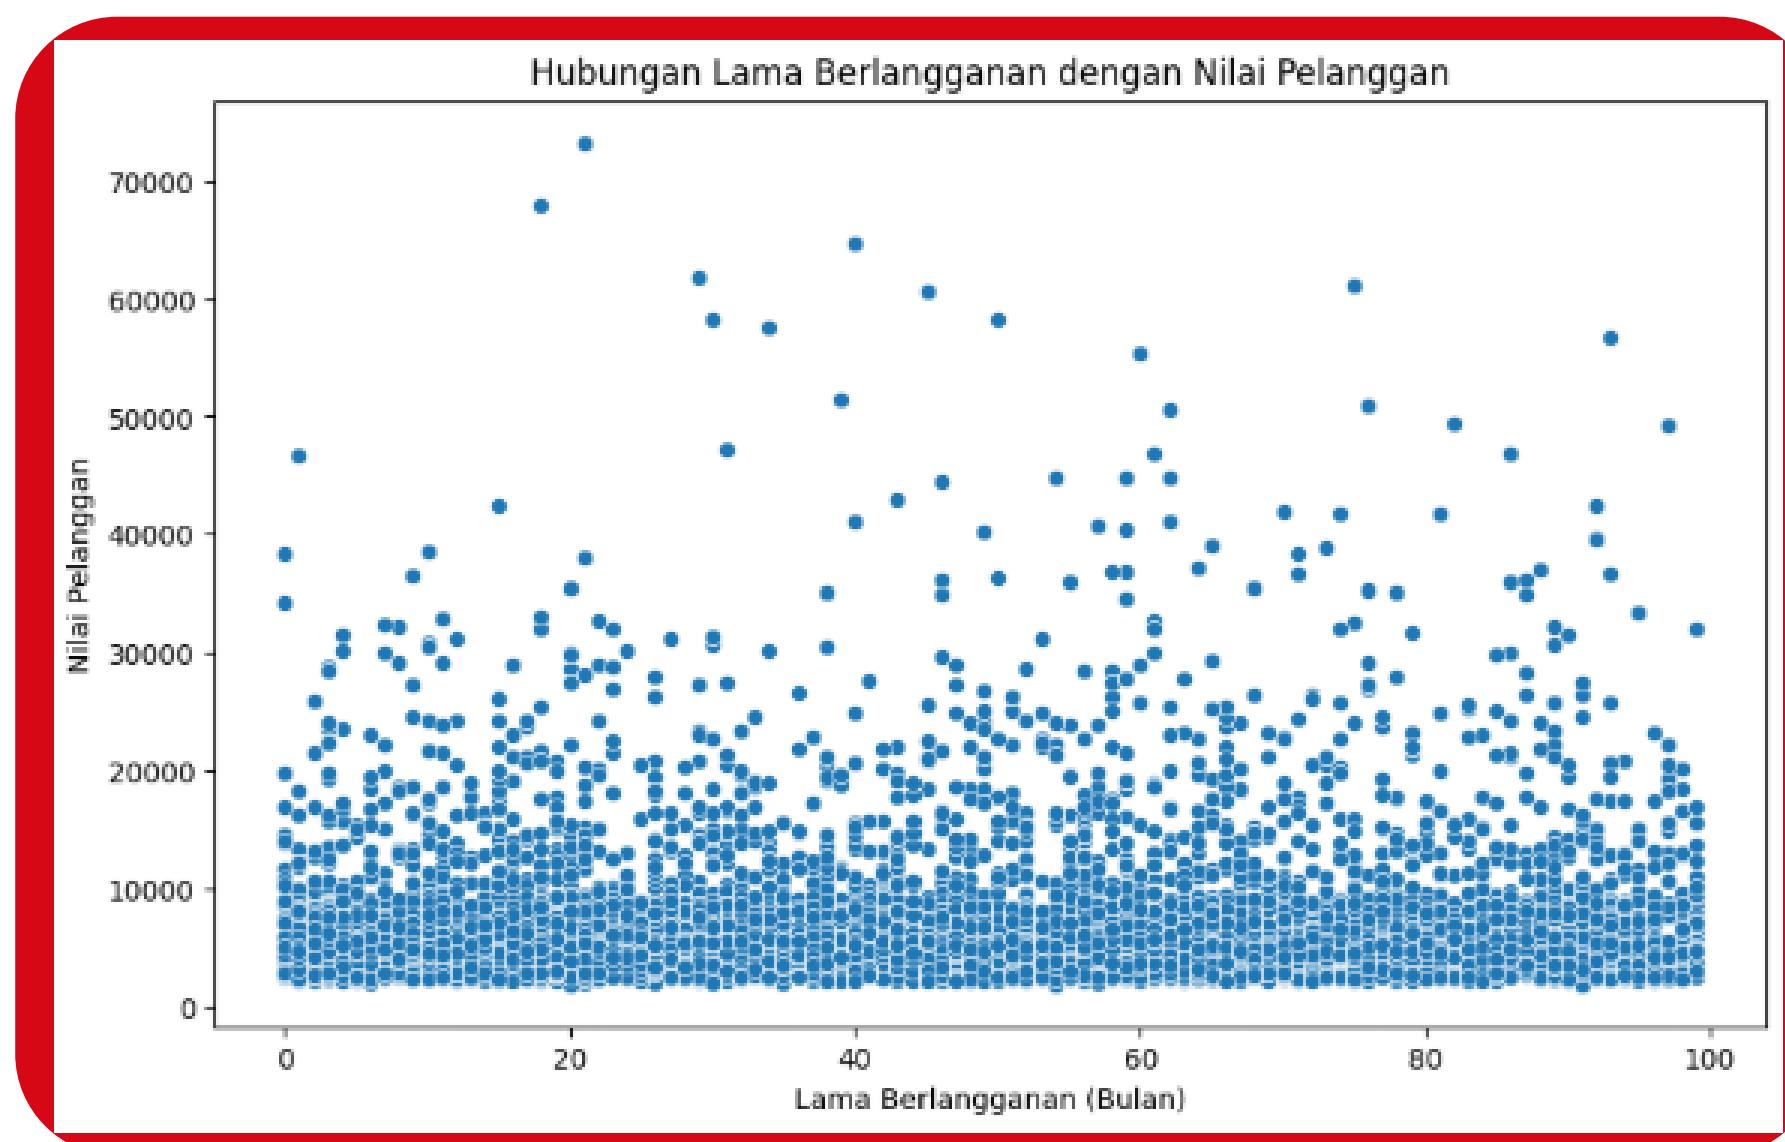
Apakah Pelanggan dengan Coverage 'Premium' Cenderung memiliki Customer Lifetime Value yang lebih tinggi dibandingkan dengan mereka yang memiliki coverage 'Basic' atau 'Extended'?

Berdasarkan visualisasi box plot di samping, terlihat bahwa pelanggan dengan coverage "premium" memiliki rata-rata, median, dan kuartil ke-75 yang lebih tinggi dibandingkan dibandingkan coverage basic dan extended.

Bisa disimpulkan bahwa **pelanggan yang memilih coverage Premium cenderung memberikan nilai lebih besar.**

# Data Understanding

## EDA



5

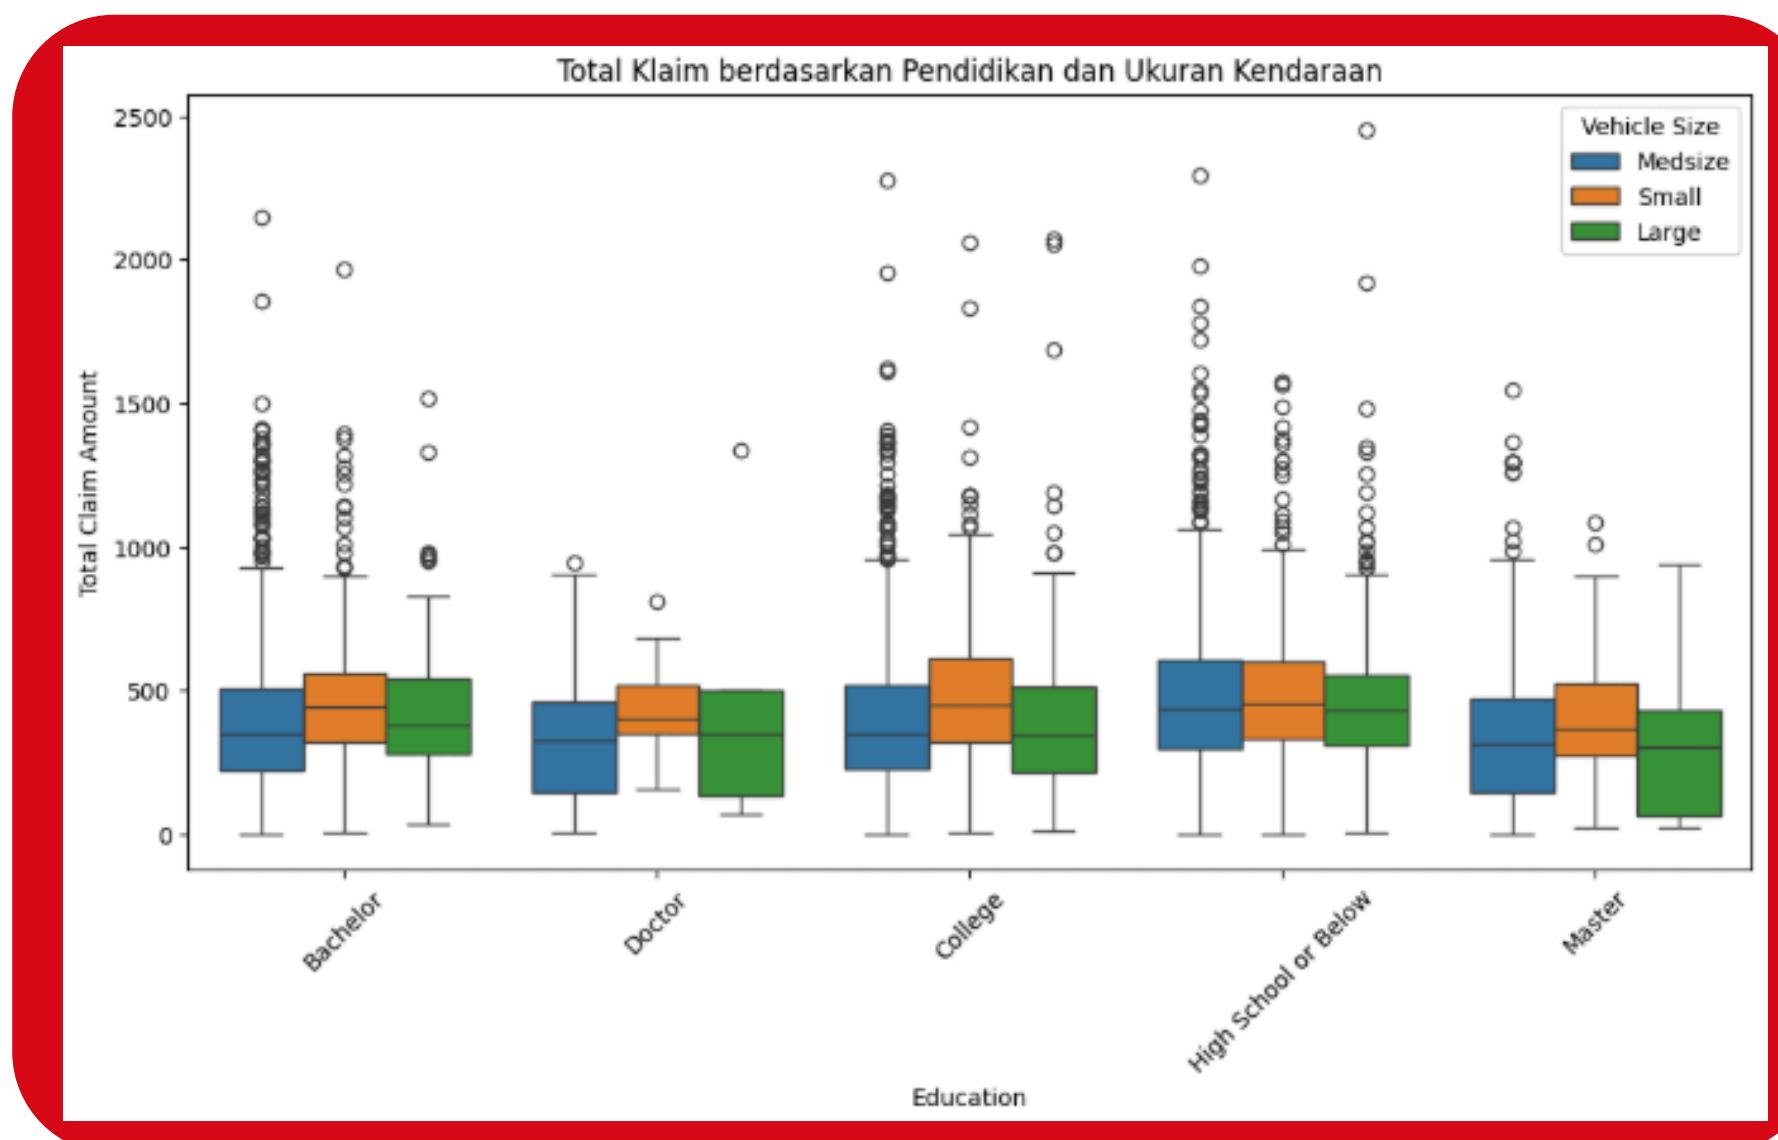
Apakah nilai pelanggan meningkat seiring bertambahnya durasi hubungan mereka dengan perusahaan?

Berdasarkan visualisasi box di samping, terlihat bahwa Distribusi tidak merata, Tidak ada tren linear yang kuat, Beberapa outlier dengan nilai pelanggan tinggi (>50.000) tersebar di berbagai durasi berlangganan

Ini mengindikasikan bahwa **lama berlangganan bukan faktor dominan** dalam menentukan nilai pelanggan.

# Data Understanding

## EDA



6

Explorasi hubungan antara Education, Vehicle Size dan Total Klaim dari sini

Berdasarkan Box Plot di samping, secara keseluruhan, kendaraan berukuran kecil cenderung memiliki rata-rata klaim lebih tinggi dibandingkan ukuran lainnya, kecuali pada kelompok Doctor yang menunjukkan konsistensi nilai klaim untuk semua ukuran kendaraan.

Hal ini mengindikasikan bahwa **tingkat pendidikan dan ukuran kendaraan dapat memiliki pengaruh** terhadap pola pengajuan klaim asuransi.

1

## Business Understanding

2

## Data Understanding

3

## Data Preparation

4

## Data Modelling

5

## Wrap-Up Summary

# Data Preparation

## Inconsistent Value Handling

Number of unique values in column State:

```
State
California      1905
Oregon          1535
Arizona          1018
Nevada           542
Washington       480
Name: count, dtype: int64
```

Number of unique values in column Coverage:

```
Coverage
Basic            2920
Extended         1453
Premium          441
Name: count, dtype: int64
```

Number of unique values in column Education:

```
Education
Bachelor          1656
High School or Below 1587
College            1584
Master              453
Doctor              200
Name: count, dtype: int64
```

Number of unique values in column EmploymentStatus:

```
EmploymentStatus
Employed          3398
Unemployed        1404
Medical Leave     267
Disabled           240
Retired            171
Name: count, dtype: int64
```

Number of unique values in column Gender:

```
Gender
F                2821
M                2659
Name: count, dtype: int64
```

Number of unique values in column Location Code:

```
Location Code
Suburban          3462
Rural              1052
Urban              966
Name: count, dtype: int64
```

Number of unique values in column Marital Status:

```
Marital Status
Married            3197
Single             1467
Divorced           816
Name: count, dtype: int64
```

Number of unique values in column Policy Type:

```
Policy Type
Personal Auto      4095
Corporate Auto     1148
Special Auto        237
Name: count, dtype: int64
```

# Data Preparation

## Inconsistent Value Handling

Number of unique values in column Policy:

Policy	Count
Personal L3	2060
Personal L2	1284
Personal L1	751
Corporate L3	578
Corporate L2	355
Corporate L1	215
Special L3	97
Special L2	92
Special L1	48

Name: count, dtype: int64

Number of unique values in column Renew Offer Type:

Renew Offer Type	Count
Offer1	2241
Offer2	1789
Offer3	833
Offer4	617

Name: count, dtype: int64

Number of unique values in column Sales Channel:

Sales Channel	Count
Agent	2016
Branch	1583
Call Center	1054
Web	827

Name: count, dtype: int64

Number of unique values in column Vehicle Class:

Vehicle Class	Count
Four-Door Car	2728
Two-Door Car	1155
SUV	1089
Sports Car	295
Luxury SUV	121
Luxury Car	92

Name: count, dtype: int64

Tidak ada nilai pada dataset yang inconsistent

# Data Preparation

## Duplication Handling

```
[ ] print("Jumlah duplikasi data : " + str(data.duplicated().sum()))  
→ Jumlah duplikasi data : 0
```

Terlihat bahwa dataset ini tidak mempunyai baris duplikat, sehingga tidak perlu dilakukan penanganan.

# Data Preparation

## Outliers Handling

Column	Data Below LB	Data Above UB	Total Outliers
Customer Lifetime Value	0	495	495
Income	0	0	0
Monthly Premium Auto	0	261	261
Months Since Last Claim	0	0	0
Months Since Policy Inception	0	0	0
Total Claim Amount	0	376	376

Semua outlier berada di atas Upper Bound, Maka dari itu, kita menggunakan **metode capping**, yaitu dengan mengganti nilai yang berada di atas upper bound menjadi nilai upper bound

1

Business Understanding

2

Data Understanding

3

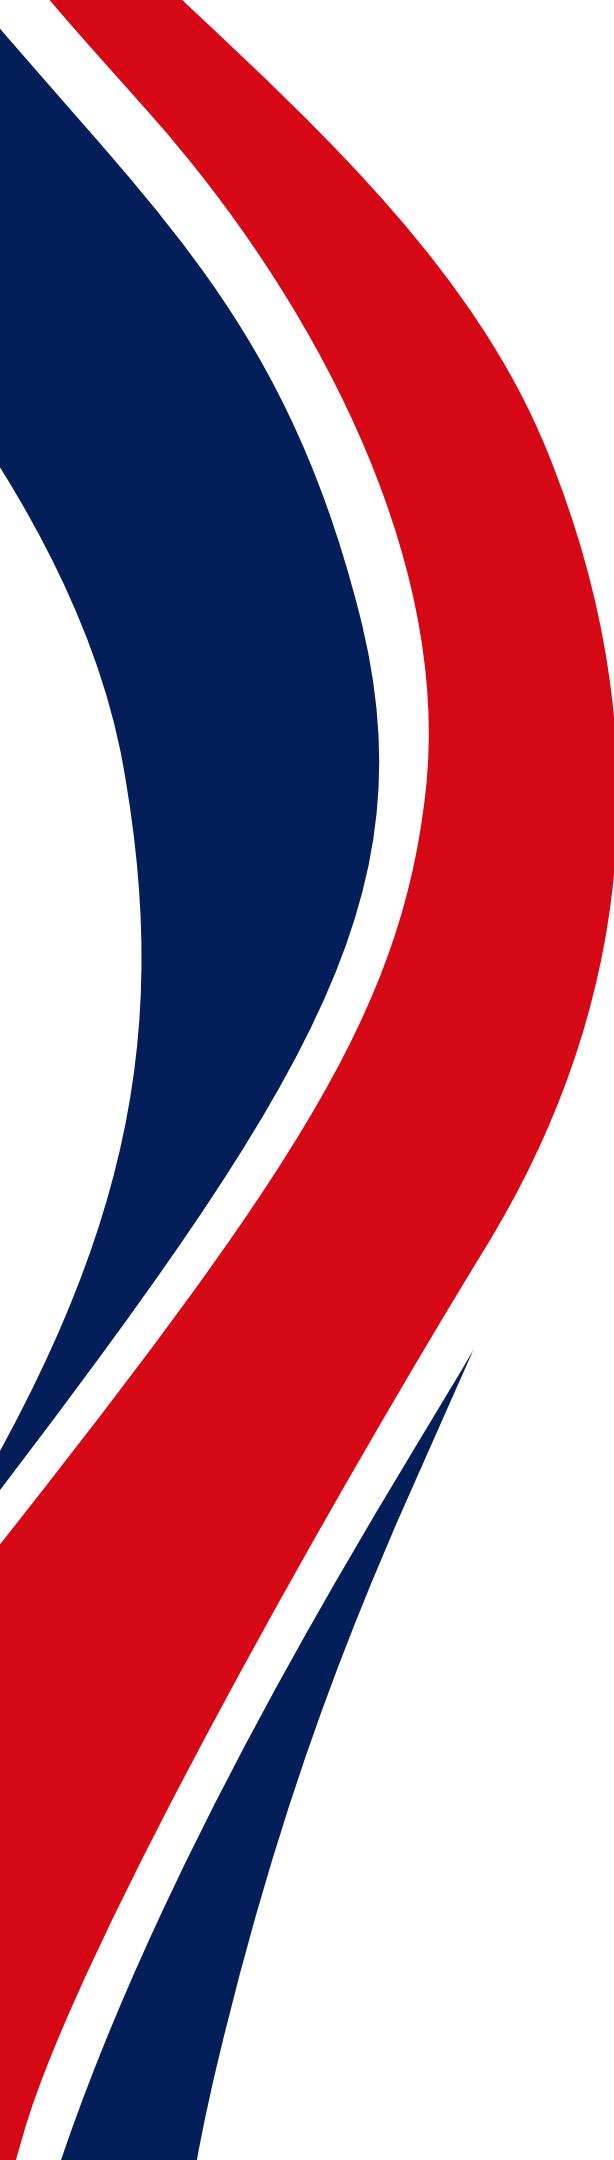
Data Preparation

4

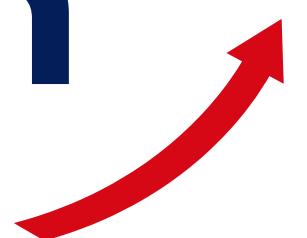
Data Modelling

5

Wrap-Up Summary



# Data Modelling **Classification**



# Data Modelling

## Classification Model

**Model untuk mengklasifikasi respon pengguna terhadap kampanye pemasaran**

Dependent Variabel (Target) : **Response** (Respon pelanggan terhadap kampanye pemasaran (Yes/No)

Model yang digunakan adalah **LightGBM Classifier**, yang dipilih karena efisiensinya dalam menangani dataset besar, kemampuannya untuk bekerja dengan fitur kategorikal yang di-encode, serta performanya yang baik pada data yang tidak seimbang. Untuk meningkatkan performa, dilakukan tuning hyperparameter menggunakan **RandomizedSearchCV** dengan metrik evaluasi F1 Macro, yang memastikan prediksi yang seimbang antara kelas target. Proses validasi menggunakan **Stratified K-Fold Cross-Validation** untuk menjaga distribusi kelas yang konsisten di setiap lipatan.

# Data Modelling

## Classification Model (Preprocessing)

- **Handle Missing Values**
  - Mean (rata-rata) untuk Income (**numerical** normal)
  - Median (nilai tengah) untuk Total Claim Amount (**numerical** skewed/tidak normal)
  - Mode (nilai terbanyak) untuk Coverage (**categorical**)
- **Encoding**
  - Fitur kategorikal diubah menjadi representasi numerik dengan **one-hot encoding**.

# Data Modelling **Classification Model**

## Parameter Grid for RandomizedSearchCV

```
param_dist = {  
    'n_estimators': randint(100, 500),  
    'learning_rate': uniform(0.01, 0.2),  
    'max_depth': randint(3, 10),  
    'subsample': uniform(0.6, 0.4),  
    'colsample_bytree': uniform(0.6, 0.4),  
    'min_child_samples': randint(10, 50),  
    'reg_alpha': uniform(0, 0.1),  
    'reg_lambda': uniform(0.7, 1.0)  
}
```

## Initialize LightGBM Model

```
lgbm_model =  
    LGBMClassifier(random_state=42)
```

# Data Modelling Classification Model

## RandomizedSearchCV

```
# Perform RandomizedSearchCV
random_search = RandomizedSearchCV(
    estimator=lgbm_model,
    param_distributions=param_dist,
    n_iter=100,
    scoring='f1_macro',
    cv=StratifiedKFold(n_splits=5, shuffle=True, random_state=42),
    verbose=2,
    random_state=42,
    n_jobs=-1
)
```

```
# Fit the Random Search Model
random_search.fit(X_train_preprocessed, y_train)
```

## Best parameters & Best score

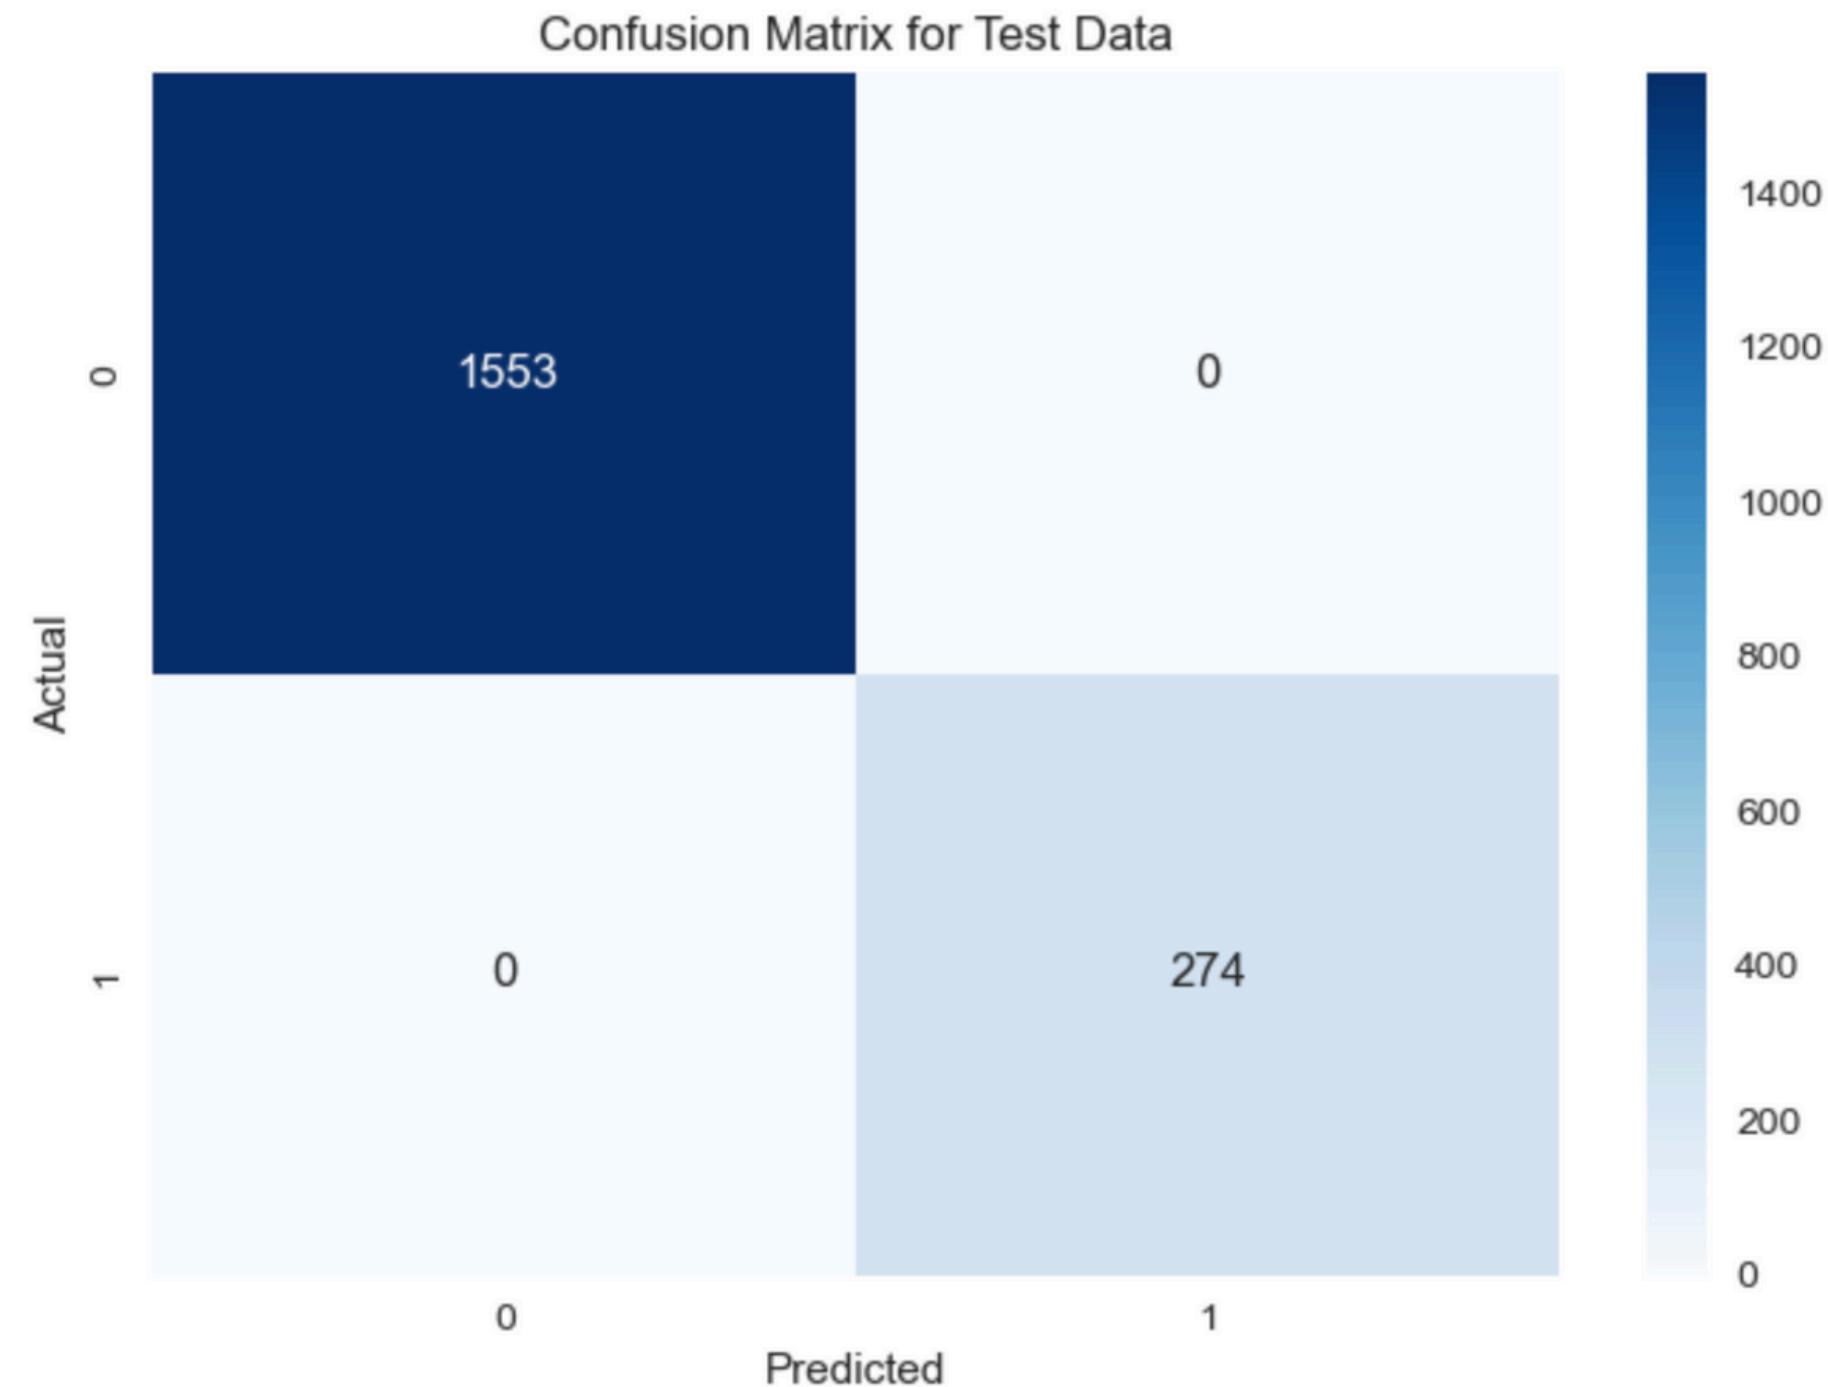
Best parameters:

{'colsample\_bytree': 0.6946740774728315,  
'learning\_rate': 0.19153874126970927,  
'max\_depth': 7,  
'min\_child\_samples': 13,  
'n\_estimators': 391,  
'reg\_alpha': 0.03762595855309158,  
'reg\_lambda': 0.7835007166986687,  
'subsample': 0.9108587663709747}

Best score: 0.9722388932680406

# Data Modelling

# Classification Model



# Data Modelling

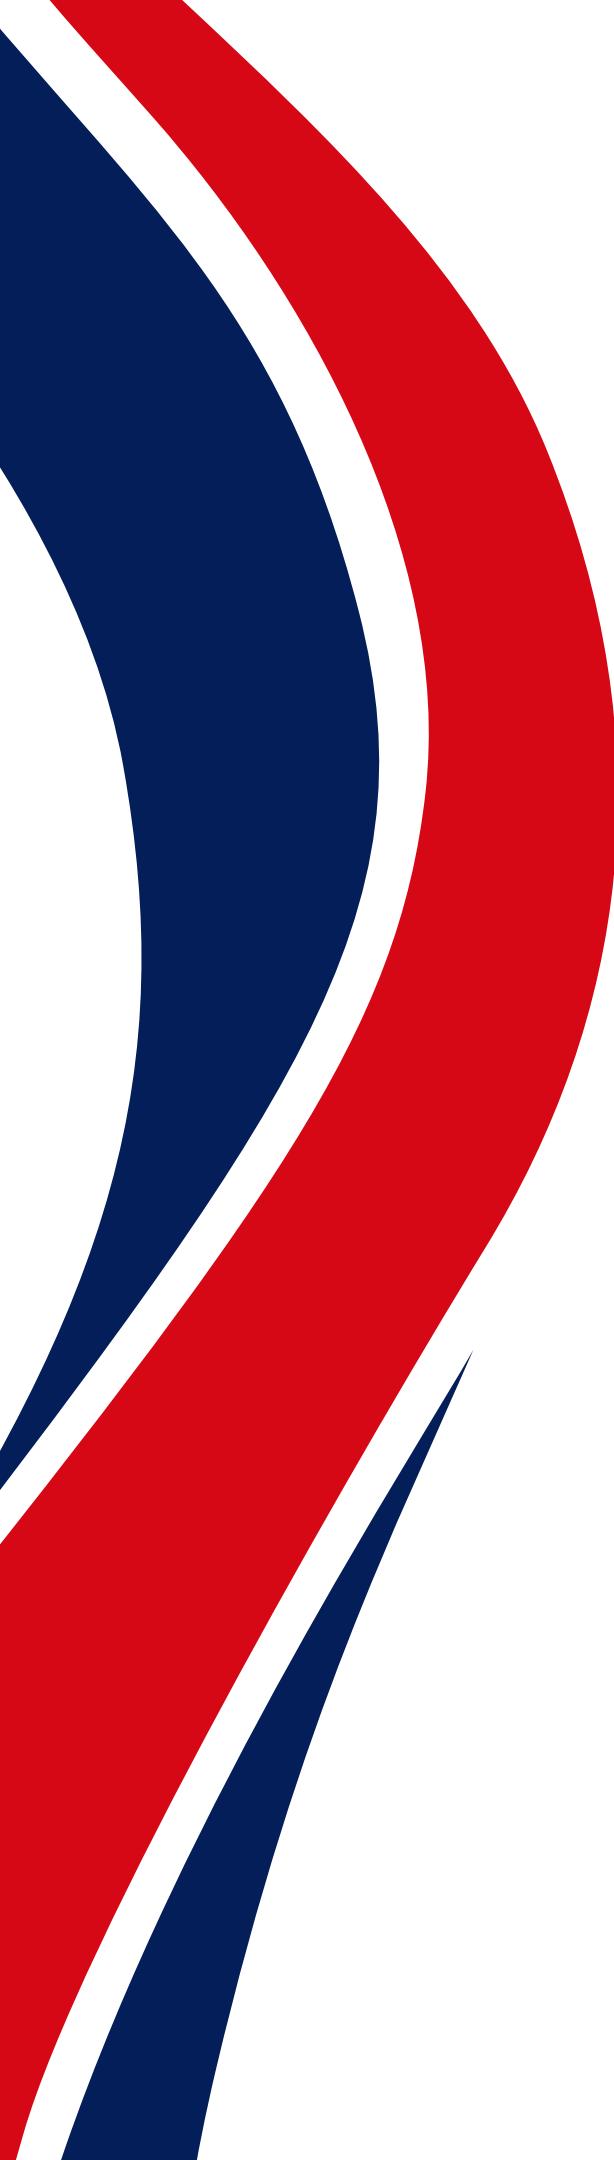
# Classification Model

**Tim Proyek APAP (Capek)**



0.97647

Nilai F1-Score = 0.97647 menunjukkan bahwa model memiliki performa yang sangat baik



# Data Modelling **Regression**



# Data Modelling

## Regression Model

**Model untuk memprediksi total nilai yang diberikan pelanggan selama masa aktif customer tersebut**

Dependent Variabel (Target) : **Customer Lifetime Value**

Model yang Digunakan

- **LightGBM Regressor (lgb.LGBMRegressor)** :

1. LightGBM tuh super cepat, terutama kalau datanya gede atau fiturnya banyak. Dia nggak ngabisin waktu lama buat training dibanding model lain kayak Random Forest atau XGBoost.
2. LightGBM dirancang buat dataset besar dan high-dimensional. Jadi kalau datanya ribet (misalnya ada banyak fitur), dia tetap jalan mulus.
3. Terkenal akurat buat kasus prediksi kayak ini. Apalagi kalau dibanding model linear kayak Linear Regression, LightGBM biasanya menang telak, terutama kalau datanya non-linear.
4. LightGBM punya optimasi bagus buat menangani missing value atau fitur yang skala nilainya beda-beda. Jadi nggak usah repot-repot preprocessing ribet, tinggal standardize aja.

# Data Modelling

## Regression Model (Preprocessing)

### Handle Missing Value

Penggunaan median untuk data numerik dipilih karena lebih robust terhadap outlier, sedangkan mode untuk data kategorikal dipilih karena merupakan nilai yang paling umum dalam kategori tersebut.

```
# Handle missing values
train_data_cleaned.fillna(train_data_cleaned.median(numeric_only=True), inplace=True)
test_data_cleaned.fillna(test_data_cleaned.median(numeric_only=True), inplace=True)
```

# Data Modelling

## Regression Model

**Feature Selection :**

- X (fitur): semua kolom kecuali 'Customer Lifetime Value'
- y (target): hanya kolom 'Customer Lifetime Value'

```
# Separate features and target
X = train_data_cleaned.drop(columns=['Customer Lifetime Value'])
y = train_data_cleaned['Customer Lifetime Value']
```

# Data Modelling

## Regression Model

```
# Create a LightGBM model
lgb_model = lgb.LGBMRegressor(random_state=42)

# Define hyperparameters for tuning
param_grid = {
    'n_estimators': [100, 200, 500],
    'learning_rate': [0.01, 0.05, 0.1],
    'max_depth': [4, 6, 8, 10],
    'num_leaves': [31, 50, 100],
}

# Perform Grid Search
grid_search = GridSearchCV(estimator=lgb_model, param_grid=param_grid, cv=3, scoring='r2', verbose=1, n_jobs=-1)
grid_search.fit(X_train, y_train)

# Best model from grid search
best_lgb_model = grid_search.best_estimator_

# Predict on validation set with the best model
y_val_pred = best_lgb_model.predict(X_val)
```

Proses pencarian kombinasi parameter terbaik dilakukan menggunakan GridSearchCV dengan 3-fold cross-validation.

Setelah Grid Search selesai, model dengan kombinasi hyperparameter terbaik dipilih sebagai best\_lgb\_model.

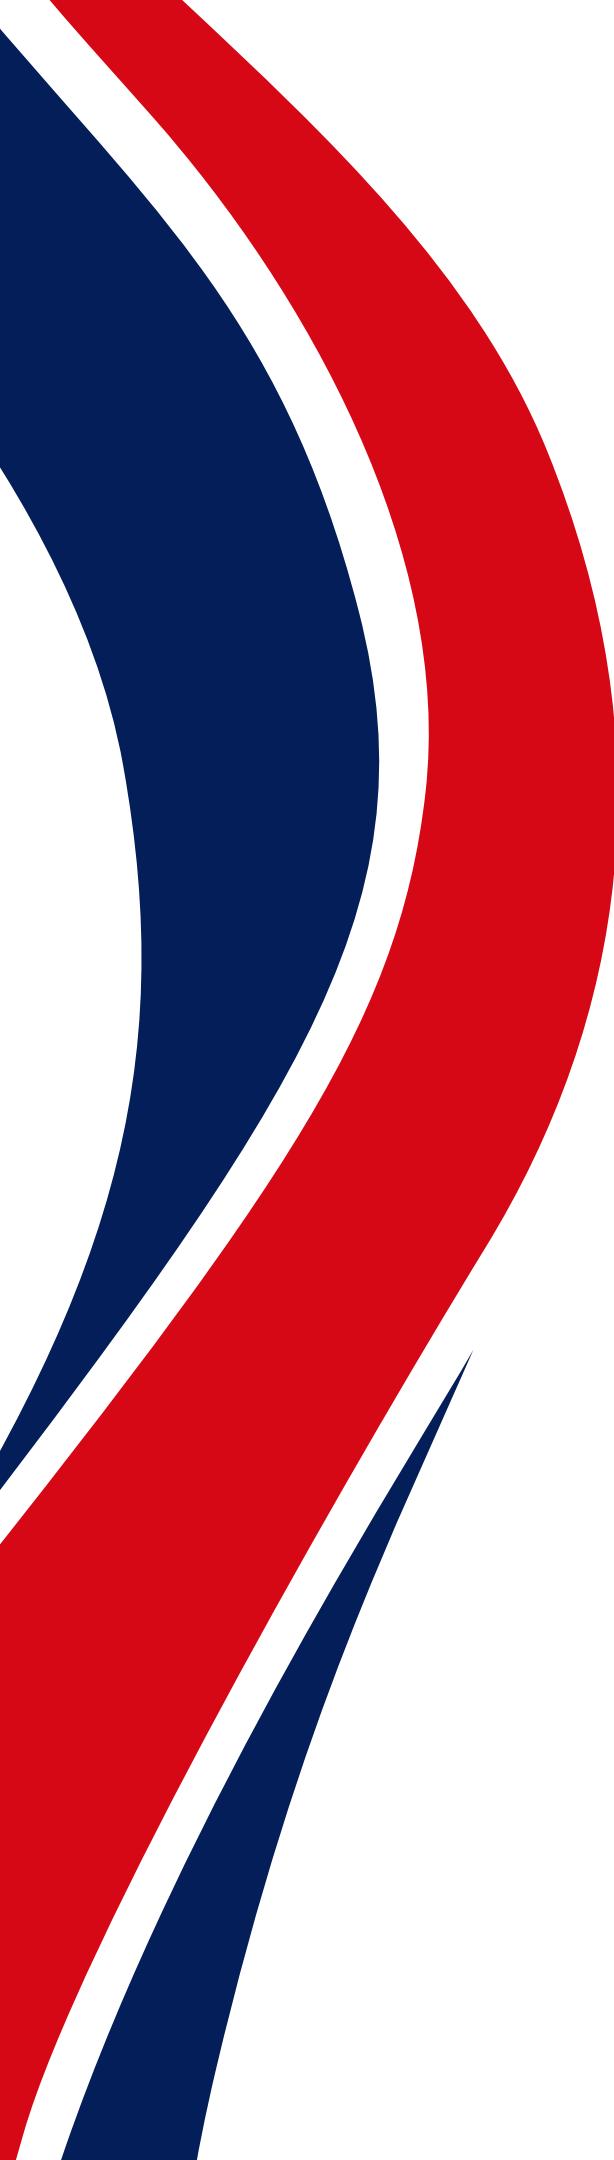
**param\_grid** = {  
 • n\_estimators (jumlah pohon): [100, 200, 500].  
 • learning\_rate (kecepatan belajar): [0.01, 0.05, 0.1].  
 • max\_depth (kedalaman pohon): [4, 6, 8, 10].  
 • num\_leaves (jumlah daun per pohon): [31, 50, 100].  
}  
  
best\_lgb\_model  
LGBMRegressor(max\_depth=4, random\_state=42)

Proses tuning memastikan model tidak hanya akurat, tetapi juga cukup robust untuk data baru.

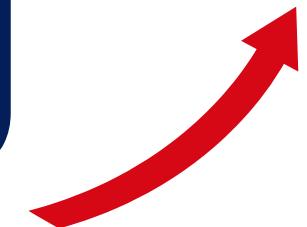
# Data Modelling

# Regression Model

Precision	
MAE	1619.3089
MSE	13180284.9358
RMSE	3630.4662
R_squared	0.7014



# Data Modelling **Clustering**



# Data Modelling

## Clustering Model

**Model Clustering bertujuan untuk mengelompokkan data menjadi kelompok atau cluster berdasarkan kemiripan antar data**

### Pemilihan Jumlah Cluster

Explained Variance Ratio oleh komponen tunggal: [0.32492627]

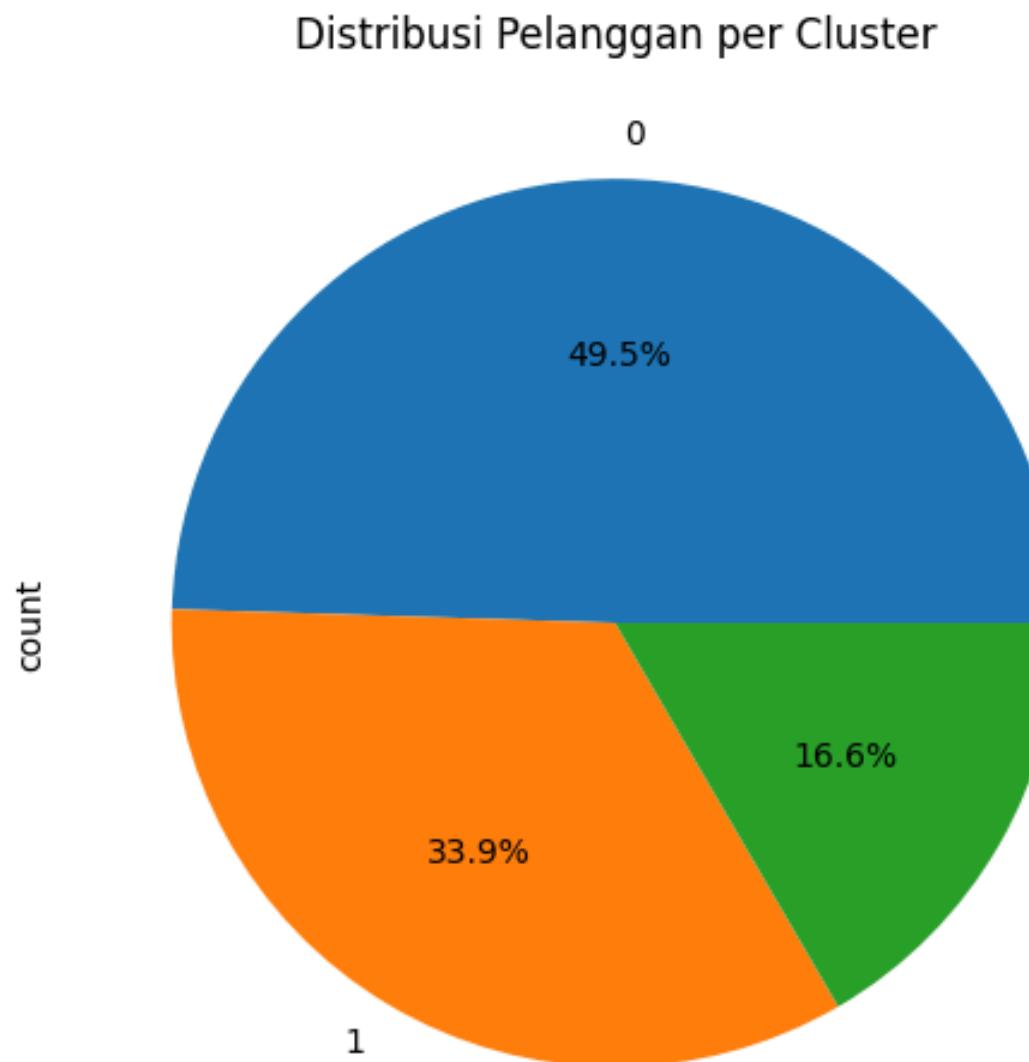
- Jumlah Cluster (PCA 1D): 2, Silhouette Score: 0.8430
- **Jumlah Cluster (PCA 1D): 3, Silhouette Score: 0.8659**
- Jumlah Cluster (PCA 1D): 4, Silhouette Score: 0.8548
- Jumlah Cluster (PCA 1D): 5, Silhouette Score: 0.8629
- Jumlah Cluster (PCA 1D): 6, Silhouette Score: 0.7071
- Jumlah Cluster (PCA 1D): 7, Silhouette Score: 0.6779
- Jumlah Cluster (PCA 1D): 8, Silhouette Score: 0.6568
- Jumlah Cluster (PCA 1D): 9, Silhouette Score: 0.6063
- Jumlah Cluster (PCA 1D): 10, Silhouette Score: 0.5698

# Data Modelling

# Clustering Model

## Interpretasi Hasil Clustering

### Distribusi Frekuensi



#### 1. Cluster 0 - Basic Customer (Biru): 49.5%

- Segmen terbesar
- 2,713 pelanggan
- Mayoritas pengguna asuransi dasar

#### 2. Cluster 1 - Regular Customer (Oranye): 33.9%

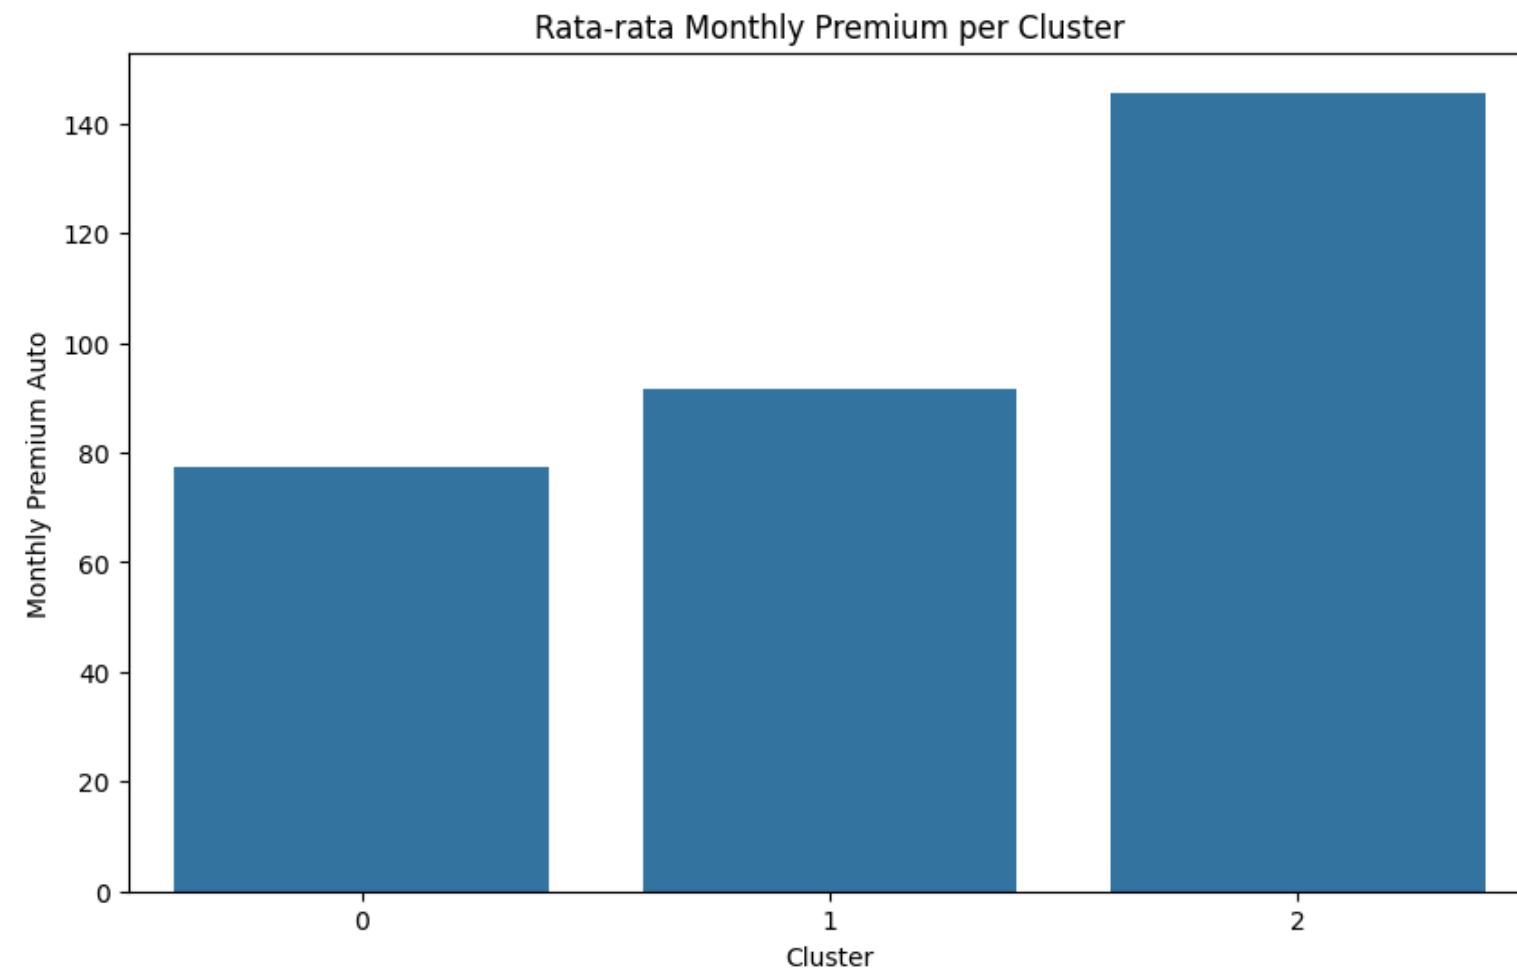
- Segmen menengah
- 1,857 pelanggan
- Pelanggan dengan nilai premi moderat

#### 3. Cluster 2 - Premium Customer (Hijau): 16.6%

- Segmen terkecil
- 910 pelanggan
- Pelanggan dengan nilai CLV tertinggi

# Data Modelling Clustering Model

## Interpretasi Hasil Clustering Monthly Premium



### Cluster 0 - Segmen Basic (77.28/bulan):

- Kelompok dengan premi terendah
- Cocok untuk nasabah yang menginginkan perlindungan dasar
- Mayoritas pengguna mobil four-door car standar

### Cluster 1 - Segmen Menengah (91.58/bulan):

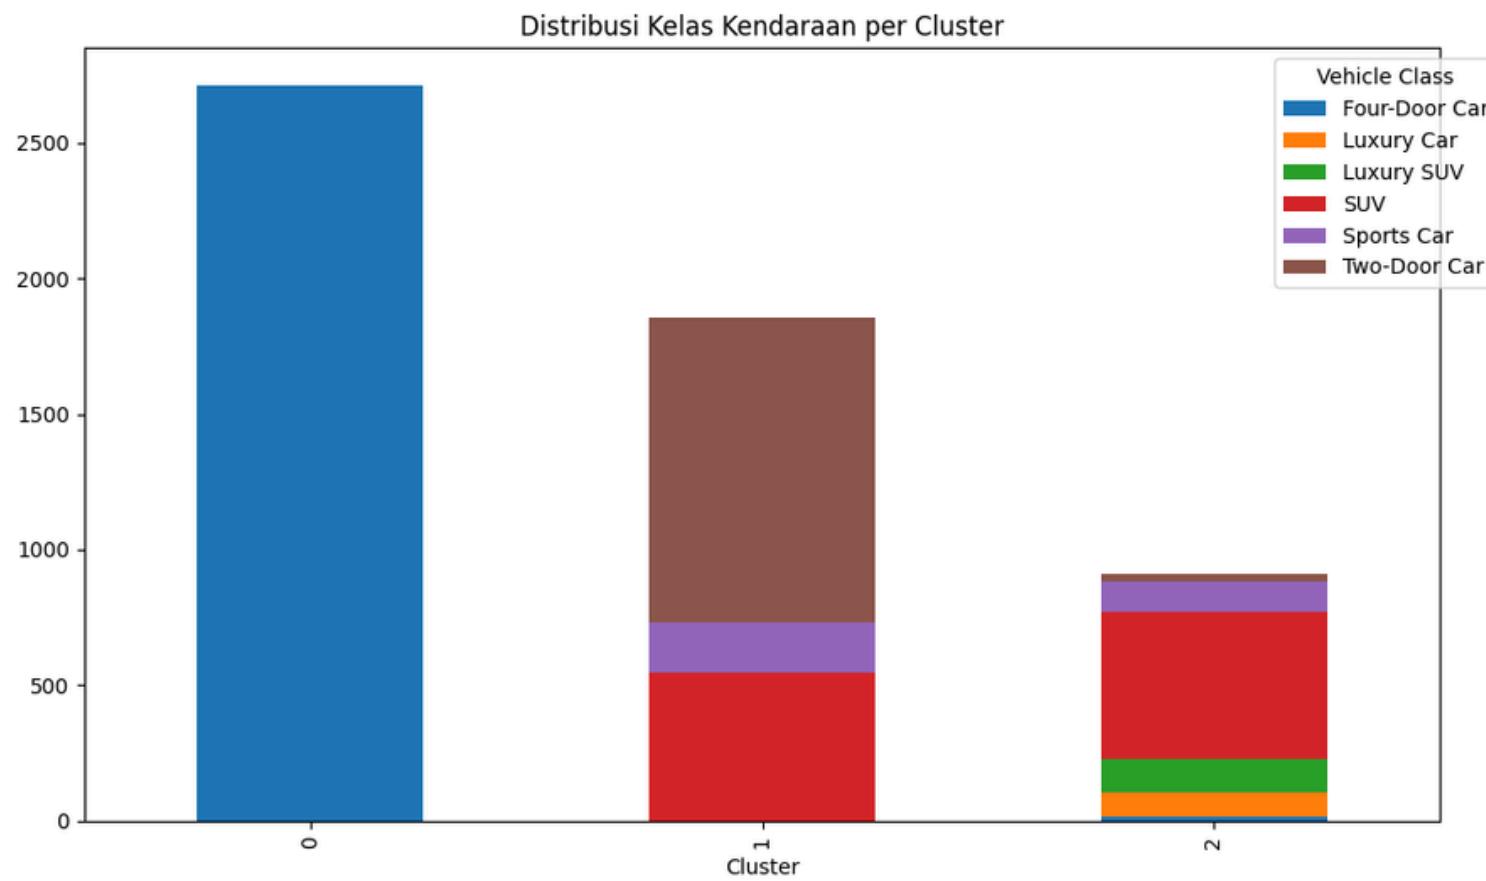
- Premi moderat, 18.5% lebih tinggi dari Cluster 0
- Target pasar kelas menengah
- Dominan pengguna two-door car dan SUV

### Cluster 2 - Segmen Premium (145.65/bulan):

- Premi tertinggi, hampir 2x lipat dari Cluster 0
- Nasabah high-value dengan mobil mewah (luxury cars & SUVs)
- Memiliki coverage premium terbanyak

# Data Modelling Clustering Model

## Interpretasi Hasil Clustering Kelas Kendaraan



### Cluster 0 (2713 pelanggan):

- Hampir 100% menggunakan Four-Door Car
- Mencerminkan segmen ekonomis/basic

### Cluster 1 (1857 pelanggan):

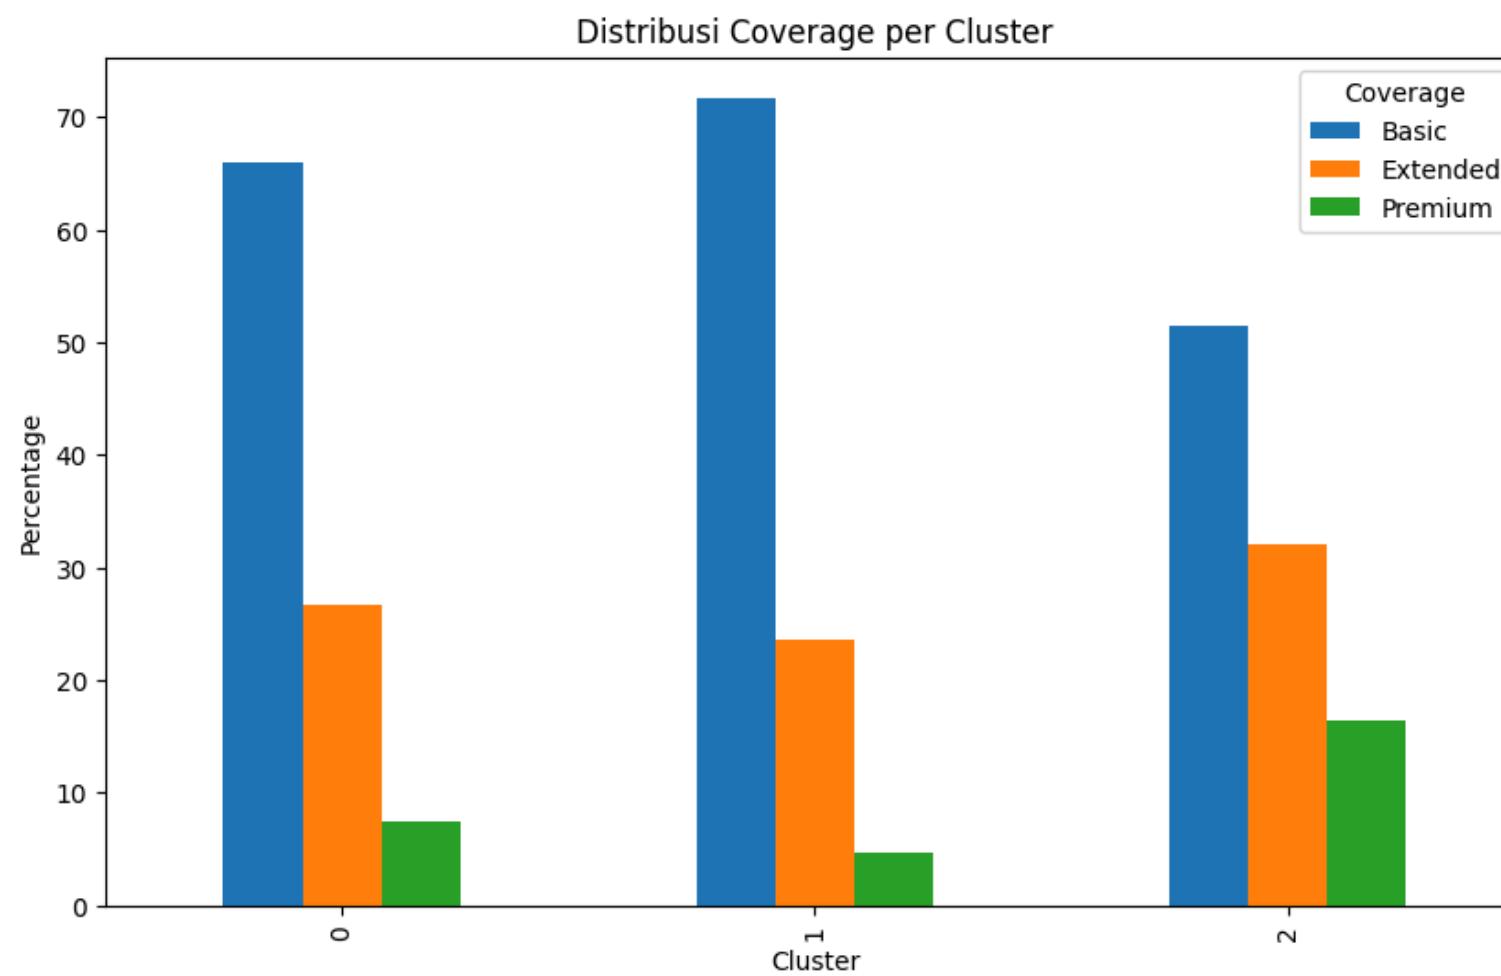
- Didominasi Two-Door Car (60.6%)
- SUV (29.3%)
- Sports Car (10.1%)
- Menunjukkan preferensi kendaraan menengah

### Cluster 2 (910 pelanggan):

- SUV mendominasi (59.8%)
- Luxury SUV (13.3%)
- Sports Car (11.9%)
- Luxury Car (9.9%)
- Mencerminkan segmen premium dengan preferensi kendaraan mewah

# Data Modelling Clustering Model

## Interpretasi Hasil Clustering Coverage



### Cluster 0:

- Basic: 65.9%
- Extended: 26.6%
- Premium: 7.5%
- Sesuai karakteristik segmen ekonomis

### Cluster 1:

- Basic tertinggi: 71.7%
- Extended: 23.6%
- Premium terendah: 4.7%
- Fokus pada proteksi dasar meski segmen menengah

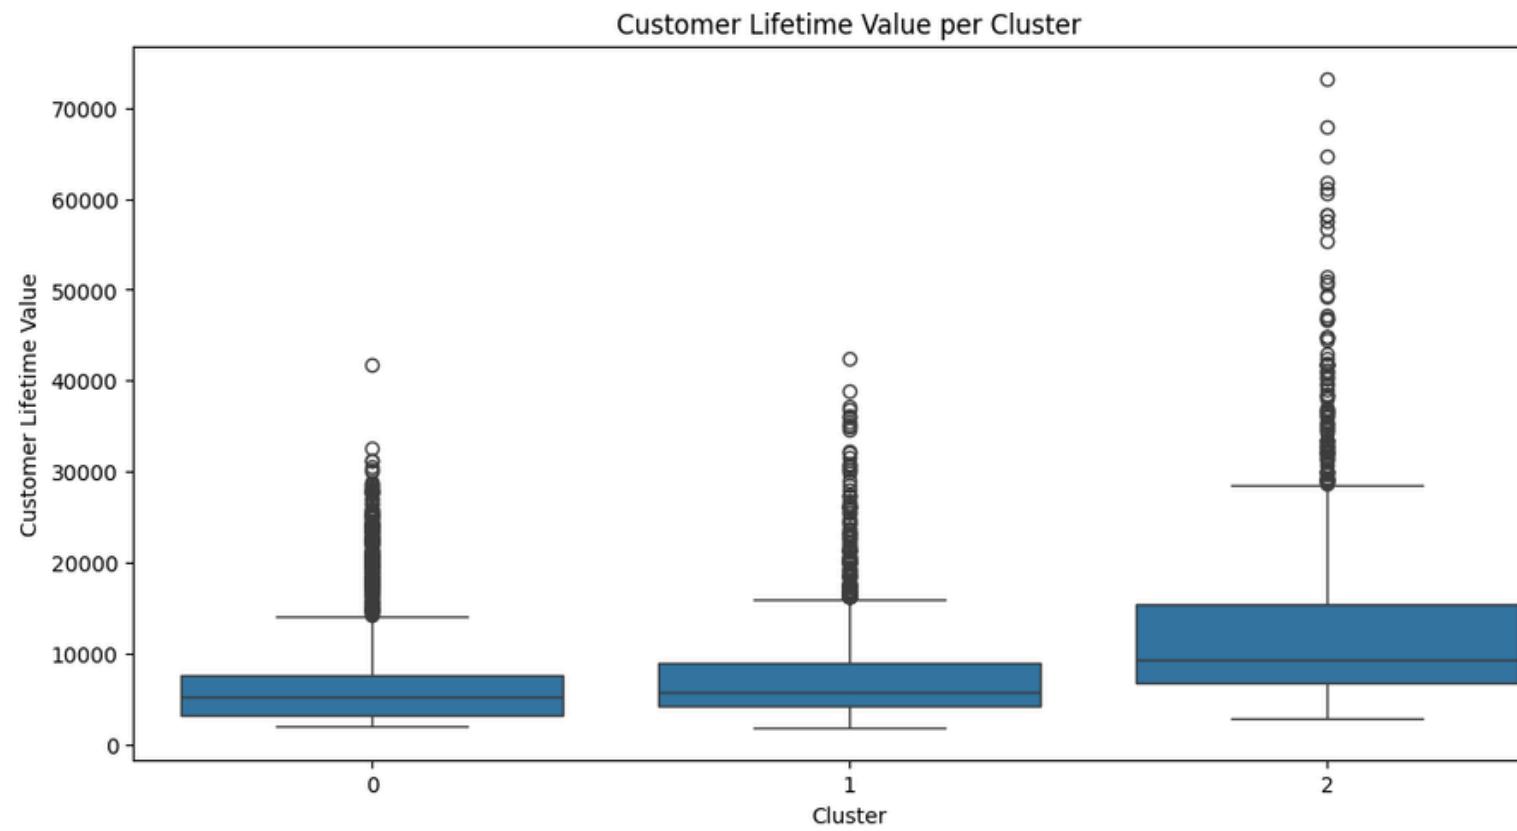
### Cluster 2:

- Basic: 51.4%
- Extended tertinggi: 32.1%
- Premium tertinggi: 16.5%
- Mencerminkan preferensi proteksi lengkap

# Data Modelling

# Clustering Model

## Interpretasi Hasil Clustering Customer Lifetime Value



### Cluster 0:

- Rata-rata CLV: \$6,565
- Range normal: \$2,000-\$15,000
- Outlier hingga \$30,000+

### Cluster 1:

- Rata-rata CLV: \$7,515
- Range normal: \$2,500-\$17,000
- Outlier hingga \$40,000+

### Cluster 2:

- Rata-rata CLV: \$13,277
- Range normal: \$4,000-\$30,000
- Outlier hingga \$70,000+

**Thank  
You** ➤  
**for attention**

